



T.C.
ULUDAĞ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



Döner Kanatlı Hava Araçları İçin Gerçek Zamanlı Tel Algılama Sistemi

Mürsel Aybars Ormanlı

031890004

Batuhan Özdemir

031890026

Burak Yavuz Çengel

031890016

BİTİRME PROJESİ

FİNAL RAPORU

BURSA 2022

T.C.
ULUDAĞ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Döner Kanatlı Hava Araçları İçin Gerçek Zamanlı Tel Algılama Sistemi

Mürsel Aybars Ormanlı

031890004

Batuhan Özdemir

031890026

Burak Yavuz Çengel

031890016

Projenin Danışmanı : Prof. Dr. Kemal Fidanboyu

ÖZET

Günümüzde pervaneli hava araçlarının telleri tespit mücadelesinde üretilen birçok farklı prensibe dayalı çeşitli sistemler bulunmaktadır. Bu sistemlerin bazıları LIDAR gibi pahalı teknolojileri kullanarak çalışırken kimisi sadece görüntü işleme tekniklerinden faydalanmaktadır. Bu çalışmada tel tespitinde aranan gerçek zamanlı çalışabilme ve düşük maliyet gibi gereksinimleri karşılayabilecek bir sistem arayışında çeşitli sistemler pozitif ve negatif yönleriyle birlikte detaylıca incelendi.

Makalenin ilerleyen kısımlarında seçilen yöntem hakkında daha detaylı bir açıklamalarda bulunuldu. Yöntemin seçiminde göz önünde bulundurulmuş kriterlere göre diğer yöntemlerin elenme sebeplerinden bahsedildi. Ardından geliştirilen yöntem detaylı bir şekilde açıklandı. Elde edilen model ile yapılan testler incelenip çıkarımlarda bulunuldu, sistemin başardıkları, sorunları ve iyileştirme önerileri sunuldu.

ABSTRACT

Nowadays, there are various systems based on many different principles produced in the struggle for detecting the wires for rotorcraft. While some of these systems use expensive technologies such as LIDAR, some use only image processing techniques. In this study, various systems were examined in detail with their positive and negative aspects in search of a system that could meet the requirements such as real-time operation and low cost in wire detection.

In the following parts of the article, more detailed explanations were made about the chosen method. The reasons for the elimination of other methods according to the criteria considered in the selection of the method were mentioned. Afterwards the developed system was explained in detail. The tests made with the obtained model were examined and inferences were made. The achievements of the system, its problems and improvement suggestions were presented.

İÇİNDEKİLER

ÖZET.....	ii
ABSTRACT.....	iii
İÇİNDEKİLER	iv
ŞEKİLLER DİZİNİ.....	vi
ÇİZELGELER DİZİNİ	viii
1. GİRİŞ	1
2. KAYNAK ARAŞTIRMASI	2
2.1. Hava Aracı Güvenlik Sistemleri için Kamera ile Tellerin Algılanması ve Konumlandırılması [1]	2
2.2. İnsansız Hava Araçları için Sentetik Veri ve Genişletilmiş Evrişimli Ağlar ile Tellerin Algılanması [2]	3
2.3. Loam ve Slam Kullanan Gerçek Zamanlı Güç Hattı Mesafesi Tespiti [3]	3
2.3.1. Nokta Bulutunun Oluşturulması	5
2.3.2. Kablo Modelleme	5
2.3.3. Elektrik Direği Çıkarımı	6
2.3.4. Mesafe Tespiti	6
2.3.5. Yapılan Deneyler	7
2.4. Kablolar için Pasif Tel Algılama Sistemi (PODS) [4]	8
2.5. W-Band Milimetrik Dalga Sensörü ile Güç Hattı Görselleştirme [5].....	10
2.6. Kentsel Arazide Alçak Uçuş Yapan Cihazların Düşük Çözünürlüklü Görüntüsü Üzerinden Tel Algılanması [6].....	12
2.7. Derin Öğrenme ile Havacılık Görsellerinden Tel Algılanması [7]	14
2.7.1. Önerilen Metod	14
2.7.2. Uygulama Aşamasına Dair Detaylar.....	16
2.7.3. End-to-End Sınıflandırma	16
2.7.4. CNN Özelliklerinin Sınıflandırılması	18
2.7.5. Çalışma Süreleri	19
2.7.6. Güç Hattı Algılamaya Dayalı Metodlar	20
2.7.7. Görselleştirme	22
2.8. Otonom Hareketli Robotlar için Hızlı ve İsabetli İnce Yapılı Nesne Algılama [8]	22
2.8.1. Giriş.....	22
2.8.2. Diğer Çalışmalar	23
2.8.3. Görüş Bazlı İnce Engel Tespiti	24
2.8.4. Engel Tespit Sistemi	26

2.8.5. Deneyler	26
2.9. Optik Görüntülerden Elektrik Teli Algılanması [9].....	27
2.10. Hava Araçları için Tel ve Kablo Tespit Sistemi [10].....	29
2.11. Karar Matrisi ve Seçilen Yöntem.....	29
3. MATERYAL VE YÖNTEM	31
3.1. Kullanılan Veri Seti.....	31
3.2. Kullanılan Yöntemin Açıklaması.....	31
3.2.1. Modelin Çalışma Prensipleri	32
3.2.2. Sabit Görseller Üzerinde Test	33
3.2.3. Video Üzerinde Test	34
4. ARAŞTIRMA SONUÇLARI	35
5. TARTIŞMA	39
6. KAYNAKÇA	40
7. TEŞEKKÜR.....	41
8. ÖZGEÇMİŞ	42

ŞEKİLLER DİZİNİ

Şekil 2.1 - Sistemin LIDAR'lı geleneksel sistemlerle blok diyagramlar aracılığıyla kıyası	4
Şekil 2.2 - Nokta bulutuna dair çıktı	7
Şekil 2.3- Deneyin Gerçekleştirildiği Yer.....	7
Şekil 2.4 - Deney Sonucu Elde Edilen Nokta Bulutu	8
Şekil 2.5 - Sistemin Blok Diyagramı	9
Şekil 2.6 - Deney bölgesinin fotoğrafı	11
Şekil 2.7 - Tel ve direklerden yansıyan sinyaller	11
Şekil 2.8 - Yeryüzüne dönük sensörle alınan dönütler	12
Şekil 2.9 – Güç hattı tespitinde kullanılmak üzere geliştirilmiş iki farklı metodun blok diyagramları	15
Şekil 2.10 - Sistemde kullanılan VGG-19 ve ResNet-50 tabanlı CNN mimarileri. Mimarilerin basamakları farklı renkler aracılığıyla gösterilmekte. Üstteki VGG-19, Alttaki ise ResNet-50	16
Şekil 2.11 - End-to-end sınıflandırma için sınıflandırma hatası yüzdeleri (a) ve (b) ön eğitilmiş ImageNet modellerini, c ise rastgele değerlerle ilklendirilmiş modele dair verileri göstermekte.....	17
Şekil 2.12 - End-to-End sınıflandırma için karışıklık matrisleri (eğitilmiş son katman ve ince ayar çekilmiş Stage 5, ImageNet ön eğitimi ve mean subtraction ön işlemesi) Sütunlar tahminleri, satırlar ise elde edilen sonuçları göstermekte.....	18
Şekil 2.13 - Mean subtraction preprocessing ile CNN özellik sınıflandırması için yüzdelik sınıflandırma hataları (solda VGG-19, sağda ResNet-50 için sonuçlar).....	18
Şekil 2.14 - En iyi CNN özellik sınıflandırması metodları için (SVM, ResNet-50, IR için Stage-4 özellikleri, VL için Stage 3 özellikleri, mean subtraction preprocessing) karışıklık matrisleri Sütunlar tahminleri, satırlar ise elde edilen sonuçları göstermekte.	19
Şekil 2.15 - Tek görsel için kümülatif çalışma süreleri (ms)	19
Şekil 2.16 - İlk satır end-to-end yaklaşım ile güç hattı olmadığı farkedilmiş örnekleri içermekte. Diğer satırlar ise sırasıyla EDLines, LSD ve Hough Transform'a dayalı bir metod ile tespit edilmiş çizgi segmentlerini içermekte.	20
Şekil 2.17- İlk satırda 4'er tane güç hatlı ve güç hatsız örnek bulunmakta. End-to-end metod bu örnekleri doğru sınıflandırmayı başaramadı. Elde edilen çıktılar 2. Satırda görülmekte. Sonraki satırlar ise EDLines, LSD ve Hough Transform'a dayalı metod ile elde edilen çıktıları göstermekte.	21
Şekil 2.18 - IR ve VL için en iyi sonuçları üreten yaklaşımlar.....	21
Şekil 2.19 - İlk sırada girdiler, ikinci sırada belirginlik haritaları, son satırda ise pilota görsel geri dönüş sağlayabilecek görsellemeler bulunmakta	22
Şekil 2.20 - FILTERSMALLCONNECTEDCOMPONENTS işlemi, engel olarak etiketlenmiş küçük bağlı parçaları listeden çıkarıyor.....	25
Şekil 2.21 - Nicel Sonuçlar. Soldaki şekil algılama algoritmamızın precision-recall eğrisi ve sağdaki şekil tamlık ölçüsünü gösterir.	26
Şekil 2.22 - Hız Karşılaştırması (fps cinsinden). 1.5GHZ dört çekirdekli Celeron yerleşik CPU üzerinde ölçüldü.....	27
Şekil 3.1- İlk ikisi tel bulunduran, son ikisi bulundurmayan örnekler [7].	31
Şekil 3.2- VGG19 Mimarisi	32

Şekil 4.1- Modelin FN ya da FP sonuç verdiği örnek görseller (İlk 6 görsel FN, son 2 görsel FP)	36
Şekil 4.2- Video üzerinde düşük olasılıklı doğru pozitif	37
Şekil 4.3- Video üzerinde Yanlış Negatif (Kararsızlık)	37
Şekil 4.4 - Yanlış negatif, kararsızlık durumu	38

ÇİZELGELER DİZİNİ

Tablo 2.1 - Yöntemlerin kıyaslanması için kullanılan Karar Matrisi	30
Tablo 3.1- Test Sonucunda Performans Ölçütleri.....	33
Tablo 4.1- Üretilen modelin kesinlik grafiği.....	35
Tablo 4.2- Modelin test verisi üstündeki sonuçları	36

1. GİRİŞ

Pervaneli hava araçları günümüzde birçok farklı çeşitte ve boyutta karşımız çıkmakta. Bu araçlar askeri, sağlık ve arama kurtarma gibi alanlarda kullanılmaktadır. Bu tarz durumlarda pilotlar, araçları alçaktan uçurmak ya da beşeri olarak kalabalık bölgelere iniş yapmak zorunda kalabiliyorlar. Kaza yapmamak için pilotlar sürekli tetikte olsalar da bazı unsurlar gözden kaçabiliyor. Bu durumlar için araçların halihazırda var olan engel tespit sistemleri ile tehlikeleri algılasalar bile teller, kablolar ve havai hatların tespiti zor olabiliyor. Güneşin yansıma açıları, sis ve yağmur gibi hava durumları ya da ağaçların bulunduğu alanlar gibi yerlerde arka planın oldukça karmaşık olması nedeniyle pilotlar ince telleri görmede oldukça zorluk yaşamakta.

Mevcut sistemlerdeki donanımlar LIDAR ve MMW (Milimeter Wave) gibi teknolojiler kullandığından oldukça pahalıya mal olmaktadır. Sistemlerin donanım odaklı olması yerine yazılıma yönelmesiyle maliyetlerde oldukça büyük düşüşler görülmekte. Yazılım odaklı olan sistemler de monoküler kameralarla tel tespiti yaparak kazaların önüne geçmeye çalışıyor. Bahsi geçen bu yazılım odaklı yaklaşımlar görüntü işlemeyi odak almaktalar. Her ne kadar maliyeti düşürseler de güç hatlarının arkaplana karışmaya meyilli, kontrastı düşük yapıları bu cisimlerin tespitini hem insan hem de geliştirilen algoritmalar için oldukça güçleştirmektedir. Bu zorlukların üstesinden gelmek için derin öğrenme gibi yöntemler özellikle son yıllarda ciddi birer ilgi odağı olmuştur.

Makalede belirlenen çözüm yöntemi üzerine derinlemesine konuşulmadan önce araştırmalar esnasında toparlanan alternatif çözüm önerileri detaylıca incelenecektir. Bu yöntemler her ne kadar seçilmemiş olsalar da çalışmanın geri kalanının idrakı açısından haklarında fikir sahibi olunması önemlidir.

2. KAYNAK ARAŞTIRMASI

2.1. Hava Aracı Güvenlik Sistemleri için Kamera ile Tellerin Algılanması ve Konumlandırılması [1]

Tel algılama için kameraların kullanımı günümüzde insansız hava araçları için oldukça ilgi gören bir yöntemdir. Bunun başlıca sebebi fazladan ekipman gerektirmeden tek bir kamera ile güvenliğin teknoloji harikasına ulaşabilecek olmasıdır. Bu yolda aşılması gereken birçok engel arasından en önemlisi zorlu hava şartlarıdır; nitekim aynı görevi yerine getirmekle görevli olan lazer radarlarının en büyük zorluğu burada başlamaktadır.

Birçok sistem kamera yoluyla algılamayı lazerler ile destekleyerek verimliliği arttırmayı hedeflemektedir. Bu çalışmada anlatılan yöntem ise maliyeti asgari düzeyde tutarken, insan gözüne zarar vermeden kilometrelerce mesafeden tel algılayabilmek için kamera kullanımını tercih etmektedir. Maliyetin olabildiğince indirilmesi adına tek bir yüksek çözünürlüklü kamera kullanımı, ayrıca tek kamera ile üçgenleme yapmak için gerekli algoritma tanımı sunulmuştur.

Sistem tel algılama süreci için derin öğrenme yöntemlerinden faydalanmaktadır. Algoritmanın eğitilmesi için faydalanılacak tel özelliklerinin temelinde lineer yapıları bulunmaktadır. Deep Wire CNN adı verilen bu derin öğrenme ağı üç aşamadan oluşmaktadır. İlk olarak görüntü hücrelere bölünüp her bir hücrenin merkezi bir çıpa noktası seçilir. Sistem hücre başı tarama yaparak verimliliği artırır, ayrıca her bir çıpa noktasının yakın çevresinde bulunan teller çıpalar ile eşleştirilir. Bu noktaların lineerlik durumuna göre tel algılama işlemi tamamlanır.

Tel algılama işlemi tamamlandıktan sonra üç boyutlu ortamda yapılandırmaya başlanır. Kameranın 3B konumunun 2B temsili olan kamera matrisini oluşturmak için kameranin başlangıç konumu hesaplanıp sonraki hareketleri görüntü yordamıyla takip edilir. Bu işlem için ORB-SLAM tabanlı bir odometri altyapısı kullanılmaktadır. Yazar bu işlem için jiroskop kullanımının etkili olabileceğini belirtmiştir.

Çalışmada üçgenleme ve tel yapılandırma işlemleri için gerekli olacak parametre hesapları ve eşitlikler detaylı bir şekilde belirtilmiştir. Bu sebeple yazılımcının matematiksel hesaplama sürecine dahil olmasına gerek kalmayıp görüntü işleme ve derin öğrenme bilgilerini katması yeterli olacaktır.

Belirli bir bölge drone'lar ile taranıp bu görüntüler üstünde işlem görülürken, elde edilen sonuçlar USF Veri Seti üzerindeki çalışmalar ile kıyaslanmıştır. Yapılan çalışma %15 daha iyi bir sonuçla 0.82 mAP elde etmiş, aynı zamanda iki katı işleme frekansına çıkmıştır. Çalışma sonucunda en çok başarısız sonucun 45 derecelik bir açıdan daha yakından tel görüntülenme durumunda elde edildiği gözleniyor.

2.2. İnsansız Hava Araçları için Sentetik Veri ve Genişletilmiş Evrişimli Ağlar ile Tellerin Algılanması [2]

Günümüzde havai hat ve kabloların kameralarla belirlenmesi oldukça zor. Çünkü kameralarda kablolar birkaç piksel kadar genişlikte görülüyor ve etraftaki başka kenar ve köşelerden zor ayrılıyor. Bu sorun derin öğrenmedeki yeni gelişmeler kullanılarak, görüntü bölütleme görevi ve evrişimli sinir ağlarının (CNN) verimliliğiyle araştırılarak çözülmeye çalışılmış. Geniş bir veri setinin yokluğu nedeniyle internette halka açık uçuş görüntüleriyle yapay bir veri seti oluşturulmuş.

Bu alanda yapılan ilk çalışmalardan biri geleneksel bilgisayar görüşü ile kabloların bulunmasıdır. Bu çalışmalar kabloları önceden belirlenmiş birtakım varsayımlar içerisinde eleterek çalışıyor. İlk olarak potansiyel kablo piksellerini kenar algılama algoritmasıyla toplayıp belirli kriterler göre filtreliyor. Ardından genel kriterlerle ve Hough ya da Radon transform varyantlarıyla toplanıyor. Bu sistem sadece spesifik senaryolarda işe yarıyor çünkü çoğu senaryo bu varsayımlara uymuyor.

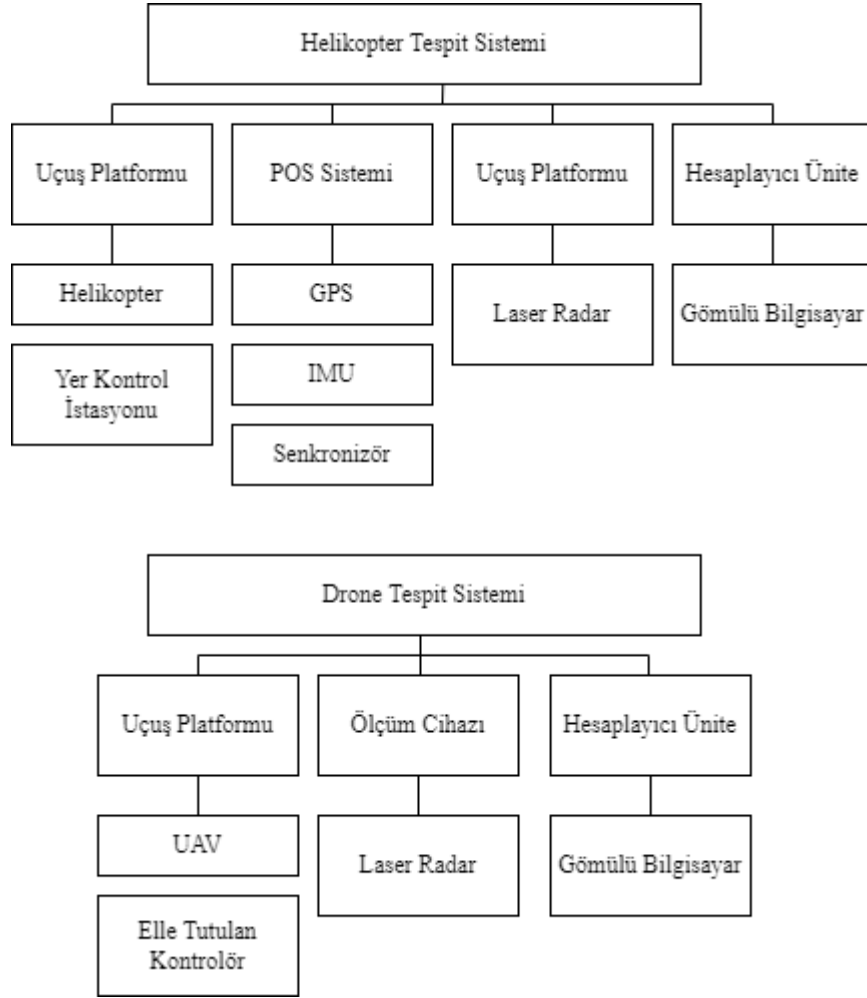
2.3. Loam ve Slam Kullanan Gerçek Zamanlı Güç Hattı Mesafesi Tespiti [3]

LIDAR'lı yaklaşımların gerçek zamanlı performans ve maliyetle ilgili problemlerini çözmek için geliştirilmiş farklı bir yöntemdir.

Şu an genelde kullanılan sistemler LIDAR kullanarak bölgenin 3 boyutlu nokta bulutunu elde ediyor. Ayrıca GPS'den faydalanarak konum bilgisine ulaşıyor ve IMU ile LIDAR'ın pozisyonu hesaplanıyor. Ardından elde edilen bu veriler senkronize edilip gömülü bilgisayara gönderiliyor ve bilgisayar tarafından gerekli işlemler yapılıyor.

Bu yöntem her ne kadar GPS ve INS'den faydalanarak işlemlerin boyutunu küçültmeyi başarsa da bazı ciddi negatif yönleri var. Bunlar sistemin oldukça masraflı olması, yerel yönetimlerden helikopter uçuşları için izin almanın çok daha zor olması ve kullanımı zahmetli ve zor ekipman.

Bu yaklaşımda ise LOAM adı verilen bir aloritmadan faydalanarak civarın kuşbakışı haritası oluşturuluyor, böylece GPS ve IMU bünyeden çıkarılıyor ve maliyet azaltılmış oluyor. Ayrıca elde edilen noktalar güç hatları ve yerdeki zemindeki diğer objeler olarak sınıflandırılıyor. Elde edilen bu bilgiler ışığında gereken güvenlik mesafesi kontrol ediliyor.



Şekil 2.1 - Sistemin LIDAR'lı geleneksel sistemlerle blok diyagramlar aracılığıyla kıyası

Sistem geleneksel sistemlerin aksine Şekil 2.1’de görüldüğü gibi sadece bir LIDAR ve mikrobilgisayar kullanarak oldukça hafif ve basit bir donanımla fonksiyonunu yerine getirebiliyor. LIDAR civara dair nokta bulutunu topluyor ve elde edilen veriyi gömülü mikrobilgisayara gönderiyor. Gömülü bilgisayar is LOAM’dan faydalanarak başlangıç noktasına göre LIDAR’ın konumunu hesaplıyor ve kuşbakışı nokta bulutu haritasını oluşturuyor. Bu işlem devam ederken eş zamanlı olarak elde edilen noktaların güç hattı ve zemindeki diğer objeler olarak sınıflandırması gerçekleştiriliyor.

Yazının sıradaki kısımlarında sistemin işleyiş aşamalarından ve yapılan bazı deneylerden bahsedilecektir.

2.3.1. Nokta Bulutunun Oluşturulması

SLAM yani Simultaneous Localization and Mapping konumlandırma ve haritalandırma işlemlerini gerçekleştirebilen bir yaklaşımdır. Bu yaklaşımın sıkıntısı gerçek zamanlı sonuçlar üretememesidir. Geliştirilen LOAM algoritması ise bu soruna çözüm üretmeyi amaçlamakta.

LOAM algoritması SLAM'i birbirinden kısmen bağımsız iki ayrı algoritmaya ayırarak bu sorunu çözmeyi hedefliyor. Elde edilen algoritmalarından ilki yüksek sıklıkla ama düşük kesinlikle odometri hesaplayıp LIDAR'ın hızını tahmin ediyor.

Oluşturulan diğer algoritma ise düşük sıklıkla elde edilen nokta bulutunu işliyor. SLAM'i bu şekilde iki parçaya bölerek gerçek zamanlı çalışabilir hale getirmekteler.

2.3.2. Kablo Modelleme

Bu aşamada nokta bulutundan faydalanarak güç hatları elde edilmekte. Sistem eldeki nokta bulutundan doğru bir şekilde güç hattı nokta gruplarını elde edip bu noktalardan güç hattı vektörleri oluşturabilmekte. Algoritmanın bu kısmı 4 adımdan oluşmakta.

2.3.2.1. Güç Hattı Nokta Bulutu Çıkarımı

Bu adımda algoritma güç hattı nokta gruplarıyla arkaplan nokta bulutunu yaklaşık olarak birbirinden ayırmakta. Zemindeki objelerle güç hattı arasındaki mesafeyi ölçmek mümkün olduğundan eşik değeri olarak yükseklik kullanılıyor. Sistem bu işlemi gerçekleştirmek için iterative threshold segmentation yönteminden faydalanmakta.

2.3.2.2. Öngörülen Görselden Kenar Çıkarılması

Bu adımda elde edilen nokta grupları öngörülen güç hattı çizgisine oturtuluyor ve bu çizgi ise sürekli bir eğri olarak sabitleniyor. Nokta bulutu verisi dijital bir görsele benzer bir yükseklik görseline dönüştürülüyor. Ardından bu görselden görüntü işleme yöntemlerinden ve Canny'den faydalanılarak kenarlar çıkarılıyor.

2.3.2.3. Çıkarılan Kenarların Güç Hattı Olarak Geri Yansıtımı

Elde edilen güç hattı eğrisinin geri yansıtımı bu aşamada tamamlanır. Çıkarımın doğruluğunu arttırmak için distance clustering algoritmasından faydalanılıyor, böylece nokta bulutu aykırılıklardan arındırılmakta.

2.3.2.4. Güç Hatlarının Uydurulması

Elde edilmiş güç hattı nokta bulutu sarkma formülü yardımıyla bir kablo modeline dönüştürülüyor.

2.3.3. Elektrik Direği Çıkarımı

Düzgün bir güvenlik alanının oluşturulabilmesi için nokta bulutunun sadece kablolar ve diğer cisimler olarak ikiye ayrılması yeterli olmamakta. Sorun çıkarabilecek bir diğer cisim sınıfı olan elektrik direklerinin de belirlenmesi gerekmektedir. Böylece elektrik direklerinin de tespiti yanı sıra yanlış alarmların da önüne geçilmekte.

Bu işlemin başarılması için öncelikle kablolarla dair noktalar total nokta bulutundan çıkarılıyor ve bunlarla bağlantılı kısımlar expansion operasyonu yardımıyla elde ediliyor. Ardından bu bağlantılı alanlara dair nokta bulutları K-means clustering algoritması ile hesaplanıyor. En sonunda tehlikeli kabul edilen yükseklikteki nokta bulutları büyüklüklerine göre değerlendirilip kablo kulesi ve diğer tehlikeli cisimler olarak sınıflandırılıyor. Elde edilen bu noktaları da total nokta bulutundan çıkardığımızda geriye sadece zemin ve zemindeki objelere dair noktalar kalıyor.

2.3.4. Mesafe Tespiti

Güç hattı ve yerin birbirine olan mesafesi eldeki modellerden ve nokta bulutlarından faydalanılarak hesaplanıyor ve elde edilen değer belirlenmiş güvenlik mesafesiyle kıyaslanıyor. İşlem 3 aşamadan oluşuyor.

- Tehlikeli güç hattı parçalarının aranıp bulunması.
- Elde edilen bu parçaların belli bir renkte gösterimi, geri kalan diğer engeller farklı bir renkle gösterilmekte.
- Tehlike seviyesi ve tehlikenin konumu gibi diğer yardımcı bilgilerin gösterimi.

Tüm bu işlemlerin sonucunda elde edilen görsel Şekil 2.2’de gösterilmiştir.




Şekil 2.2 - Nokta bulutuna dair çıktı

2.3.5. Yapılan Deneyler

Uçuş deneyi bir drone aracılığıyla bir elektrik direğinin sol üstünden ve 20 metre açığında geçilecek şekilde hesaplanan bir rotada gerçekleştiriliyor. Uçuş esnasında 10 Hz ile LIDAR nokta bulutunu elde ediyor, bilgisayar ise 1Hz hızla nokta bulutunu işliyor.



Şekil 2.3- Deneyin Gerçekleştirildiği Yer



Şekil 2.4 - Deney Sonucu Elde Edilen Nokta Bulutu

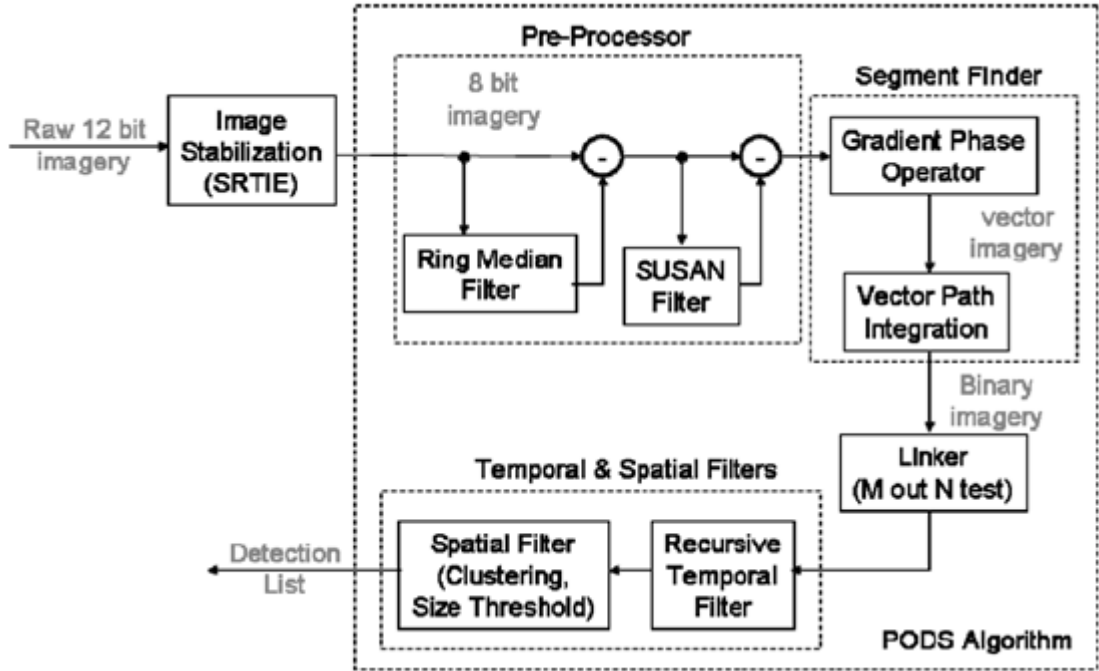
2.4. Kablolar için Pasif Tel Algılama Sistemi (PODS) [4]

Uçak ve helikopterlerin pilota yeterli refleks aralığı bırakacak şekilde güç hatlarını tespit edebilmesini hedefleyen bir sistem. Refleks aralığı 10 saniye olarak kabul edilmekte ve mesafe araçların ortalama hızları da göz önünde bulundurularak helikopterler için 770 metre, uçaklar içinse 1280 metre olarak kabul edilmekte.

Sistemin geliştirildiği dönemde aynı amaçla kullanılan diğer yaklaşımlar genellikle güç hatlarının elektromanyetik emisyonlarından faydalanarak kabloları tespit etmekteydi. Bu yaklaşım her ne kadar aktif hatlarda algılayabilse de pasif hatlara dair herhangi bir geri dönüş yapamamakta. Geliştirdikleri PODS sistemi için ilk tespit mesafesi yaptıkları deneylerde yaklaşık 5.000 metre, ve sürekli tespit mesafesi ise yaklaşık 750 metre olarak elde edilmiş.

Aktif yaklaşımların aksine görüntü işlemeye dayalı pasif sistemlere yönelmeleri beraberinde bazı teknik zorlukları da getirmiş. Bunlardan bazıları kabloların arkaplanla iç içe girmesinin mesafe tespitini zorlaştırması ve bu sebepten ötürü kablolarla diğer benzeri cisimlerin ayrımının zorlaşmasının yanı sıra sarkık yapılarından ötürü tespitlerinin zorlaşması ve yanlış alarmların sıklıkla yaşanmasıdır.

Hem LIDAR gibi aktif sistemler, hem de pasif sistemler yağmur ve sis gibi zorlu hava koşullarında istenen sonuçları vermekte güçlük çekmektedir.



Şekil 2.5 - Sistemin Blok Diyagramı

PODS algoritması 4 aşamadan oluşmakta. Bunlar:

- İşleme Öncesi: Arkaplandaki parazitlerden kurtulma işlemi. Bunu başarmak için Ring Median filtresinden ve SUSAN filtresinden faydalanılıyor.
- Segment Tespiti: Güç hatlarını andıran parçaları Gradient Phase Operator ve Vector Kernel Operator kullanarak tespit edip diğer parazitlerden ve kenarlardan ayırır.
- Segment Birleştirici: Çizgi segmentlerini birleştirir ve izole parçaları yok eder. Bu işlem için morfolojik filtreden faydalanılır.
- Spatial and Temporal Filtre: anlık ortaya çıkan yanlış alarmları ve kablo olmadığı belli olan uzun vadeli tespitleri imha eder.

Sistemde Boeing'in kendi geliştirdiği MEVS 3U işlemci kartı kullanılmakta. Temporal filtreler kullanıldığından sistem görüntünün stabilitesine oldukça bağımlı. Görüntü stabilizasyonunu Line of Sight stabilizasyon tekniğiyle ya da elektronik görsel kaydırma tekniğiyle sağlamak mümkün. Yapılan uçuş testlerinde görüntü stabilizasyonunun tespit mesafesini 5 katına kadar çıkardığı gözlemlenmekte.

Sistem herhangi bir 2 boyutlu görselleme sensörüyle çalışabilmekte ama yapılan deneylere göre uzun dalga boylu kızıl ötesi (LWIR) sensörlerle en iyi sonuçlara ulaşılmakta. Bu sensörler diğerlerinin aksine:

- Gece gündüz yüksek kaliteli görüntüler

- Görünür dalgaboylarına nazaran daha iyi kontrast
- Toz, sis, kar gibi koşullarda daha iyi sonuçlar sağlamakta.

Yaptıkları testlerde tespitlerin başlangıcı 4600 metre, tespit oranının %50'ye çıkışı 3350 metre, tam tespit ise 700 metre olarak elde edildi. Ama seçtikleri uçuş bölgesinin düzlük ve açık bir çöl ortamı olduğuna dikkat edilmesi gerekmekte.

Deneyler LWIR sensörle hem gece hem de gündüz tekrarlandı. Yanı sıra yapılan farklı testlerde zorlu hava koşullarının performansı ciddi şekilde etkilediği bilgisi elde edildi.

2.5. W-Band Milimetrik Dalga Sensörü ile Güç Hattı Görselleştirme [5]

Bu yazıda önerilen sistem mevcut yöntemlerin özellikle sis, yağmur, kar gibi zorlu hava koşullarında karşılaştığı performans sıkıntılarına çözüm getirmeyi hedefliyor. Bunu yapabilmek için LIDAR gibi geleneksel çözümlere başvurmaktaansa milimetre dalgalara (MMW) dayanan bir yaklaşım geliştirilmiş. Güç hatları periyodik olarak kıvrılan yapıları sayesinde enteresan karakteristiklere sahip olup Bragg Scattering Phenomena ile açıklanabilen dönüş sinyalleri oluşturuyor.

Bragg Scattering Phenomena ise elektromanyetik dalgaların yansımalarını açıklayan bir teorem. Normalde meteoroloji vb. Alanlarda rüzgar yönü, denizin açıklarındaki dalgaların boylarını ve hava tabakalarındaki sıcaklık farklarını hesaplamakta kullanılmaktadır.


Geliştirilen bu yaklaşım donanımsal olarak olabildiğince modüler tutulmuş 3 temel bileşenden oluşmakta:

- MMW birimi
- Veri işleme ve alma birimi
- GPS


Sisteme dair yapılan testlerde güç hatlarını ve elektrik direklerini yaklaşık 500 metreden tespit edebilmekteler. Lakin sistemin zorlu hava koşullarında iyi performans gösterdiğine dair yaptıkları iddiaları kanıtlayıcı bir deneyleri yok. Deneyi gerçekleştirdikleri gün Şekil 2.6'da görüldüğü gibi güneşli ve açık hava koşullarına sahip.



Şekil 2.6 - Deney bölgesinin fotoğrafı



Şekil 2.7 - Tel ve direklerden yansıyan sinyaller



Şekil 2.8 - Yeryüzüne dönük sensörle alınan dönütler

Şekil 2.8’de solda sensör direk karşıya ya da gökyüzüne dönükken alınan dönütün görseli bulunmakta. Sağda ise sensör yeryüzüne dönükken elde edilen dönütün görseli var. Buradan da anlaşılabileceği gibi sensör yeryüzüne en azından paralel olmadıkça ya da sinyallerin yansıyabileceği yeterince yakın bir arkaplan yüzey şekli varsa yeryüzünden ya da cisimlerden gelen dönüt sinyalleri kablolar ve direklere dair olanları örtebilmekte.

2.6. Kentsel Arazide Alçak Uçuş Yapan Cihazların Düşük Çözünürlüklü Görüntüsü Üzerinden Tel Algılanması [6]

Bu çalışmada önerilen algoritma kablo ve elektrik teli gibi ince görüntülerin tespit edilmesi için tasarlanmıştır. Çalışmada iddia edildiğine göre kötü hava şartlarına karşı yüksek performans sağlamaktadır. Kullanılan algoritma Çerçevesiz Hough Dönüşümü sonuçlarının parametrelerini kullanmaktadır. Bu parametreler ile 3B ortamda hareket algılanıp nesneler takip edilebilmektedir.

Yapılan deneyler çeşitli, çoklu ortamda ve zorlu arazi şartlarında elde edilen görüntülerle yapılmıştır. Yapılan çalışmada tek bir kare üstünde çalışan algoritmalar ve tipik bir Hough Dönüşümü yetersiz görülmüştür. Sistem zaman boyunda çalışarak hareket algılama ve nesne takibi üzerine geliştirilmiş algoritmaları uygulayacaktır.

Önerilen algoritma piksel düzeyinde hareket, telin yapısal özellikleri ve video girdisindeki ardı ardına geçen karelerde bulunan lineer yapıdan faydalanmaktadır. Ardışık karelerdeki tel piksellerinin hareketi tespit edilerek hareket bilgisi kenar algılayıcıyla birlikte çalışan bir haritalama işlemine sokulmaktadır.

İkinci aşamada, elde edilen parametreler ile Canny algoritması çalıştırılarak kenar çıkarımı yapılır. Çalışılan ve işe yaradığı görülen ekstra parametre değerleri yazıda belirtilmiştir. Benzer şekilde, bu aşama için gerekli eşitlikler de sağlanmıştır. Bu aşamada elde edilen veriler Hough Dönüşümü'nü güçlendirmek için kullanılacaktır.

Söylenildiği gibi sıradan bir Hough Dönüşümü bu işlem için yeterli olacaktır, bunun sebebi doğal ortamda ortam gürültüsünün telin yarattığı tepe noktalarından çok daha yüksek olacak olmasıdır. Genelde çerçeve boyutu aranan örüntünün boyutuna bağlıdır fakat burada geniş çerçeveler kullanılarak görseldeki bölgesel eşleşmeler taranmaktadır.

Bir sonraki aşamada hareket halindeki görüntünün takibi tartışılmıştır. Bu aşamada kullanılması gereken parametre ve eşitlikler okuyucuya verilmiştir. Ortalama piksel hareketi ve nesne takibi ağı nesnenin aldığı mesafe üzerinden hesaplanmaktadır. Model 6 DoF tel hareketi algılayacak kabiliyete sahiptir. Bu DoF küçük hava araçları ve dronelar için de geçerlidir. Bu hava araçları için farklı parametreler yazıda verilmiştir.

Canny algoritmasının çalışması için gereken üç parametre, 1000 farklı kombinasyon üzerinden denemeler yapılarak en iyi sonuçların elde edilmesiyle bulunur. İki parametre sabit tutulurken üçüncüsü değiştirilmektedir. Çerçevesiz Hough Dönüşümü iki parametre alır. Geniş çerçevesiz aramalar tercih edilerek bölgesel benzerliklere öncelik verilmiştir. 4 x 4 Çerçevesiz Hough Dönüşümü, yani asıl görselin %25 boyutu tercih edilmiştir. Parametre uzayının tespiti için Least Squares algoritması yardımıyla birinci dereceden bir polinom elde edilmiştir. İkinci ve üçüncü dereceden polinomlar da denenmiş fakat performansı arttırmamıştır.

Kullanılan veri setleri Florida ve Yeni Zelanda bölgelerinde 4 ay boyunca farklı hava ve ışıklandırma koşullarında oluşturulmuştur. Kendi halinde uçan bir hava aracına yerleştirilen kamera ile alınan bu görüntülerden toplam 9.58 dakikalık bir video elde edilmiştir. Bunun yanı sıra kurtarma görevlerinde kaza yapan ve Katrina Kasırgası'nda düşen helikopterlerin görüntüleri de kullanılmıştır. Alınan sonuçlar hesaplanırken tespit edilen kablolar ele alınmıştır. Bu durumda her karede kaçırılan tel hatalı tespit olarak sayılacaktır.

Sonuç olarak algoritma %65 algılama oranı sağlamıştır. Hibrit bir yöntem kullanıldığında en iyi sonuçlar elde edilmiştir. FA yöntemi uygulandığında %15 daha iyi sonuç alınmıştır.

2.7. Derin Öğrenme ile Havacılık Görsellerinden Tel Algılanması [7]

Bu çalışmada güç hatlarının tespiti için Convolutional Neural Network'leri (CNN) kullanan derin öğrenmeye dayalı bir sistem geliştirilmekte. VGG ve ResNet gibi ImageNet verisetinde obje algılamak için geliştirilen derin CNN algoritmalarının güç hatlarının tespitinde de iyi performans gösterdiğini ortaya koymaktalar. Elde edilen bir diğer önemli bulgu ise CNN algoritmasının önceden ImageNet verisiyle eğitilmesi durumunda çok daha iyi sonuçlara ulaşılabildiği.

Farkedilmesi bilgisayarlar için zor olan cisimleri ImageNet'in devasa verisiyle eğitilmiş CNN algoritmalarıyla tatmin edici şekilde tespit etmek mümkün. Hatta benzer şekilde ImageNet aracılığıyla eğitilmiş PASCAL VOC ve Caltech gibi tespit çalışmaları tatmin edici sonuçlar vermeyi başarmakta.

Benzeri ImageNet tabanlı CNN mimarileri birçok katmandan faydalanarak basit parçaların bütünü olan soyut gösterimler elde etmekte. Ancak güç hatlarının oldukça basit olan yapısı göz önünde bulundurulursa daha önceki katmanlardan özellikler almanın eldeki amaç için daha uygun olabileceği göz önünde bulunduruldu. Bunu test etmek içinse iki farklı metod geliştirdiler. İlkinde end-to-end sınıflandırma yapılıyor, ikincisindeyse CNN özellik sınıflandırması yapıp ara katmanlardan alınan özellikler çeşitli sınıflandırıcılara besleniyor.

Bu çalışmalar sonucu elde ettikleri sonuçlar ve kazanımlar şu şekilde listelenmekte:

- Güç hattı tespiti için kullanılabilecek görünür ışık (VL) ve kızılötesi (IR) görsellerden oluşan halka açık bir veriseti.
- CNN'lerin güç hattı teftişinde etkili bir yöntem olduğuna dair bulgular.
- ImageNet aracılığıyla ön eğitimin konu özelinde iyi dönüşler sağladığına dair sonuçlar.
- Sistemden görsel geri bildirim almak için oluşturulmuş belirginlik haritaları.

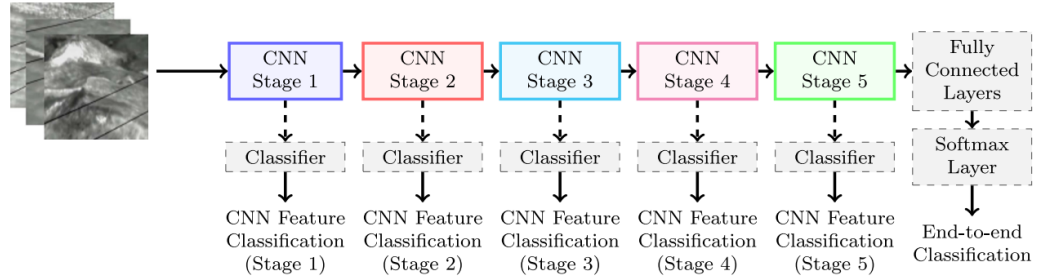
2.7.1. Önerilen Metod

Güç hattı tespitinde kullanılması için CNN'lerden faydalanan iki farklı metod geliştirilmiş. Bunlardan ilki end-to-end sınıflandırma. Bu metodda ILSVRC görsel sınıflandırması için hazırlanmış bir CNN olduğu gibi alınıyor, son katmanı yerine binary sınıflandırma yapabilmek için iki çıktılı softmax bir katman yerleştiriliyor. Ardından sadece son katman eğitiliyor ve özellik çıkarımı ve sınıflandırılması kısımlarına ince ayar çekiliyor.

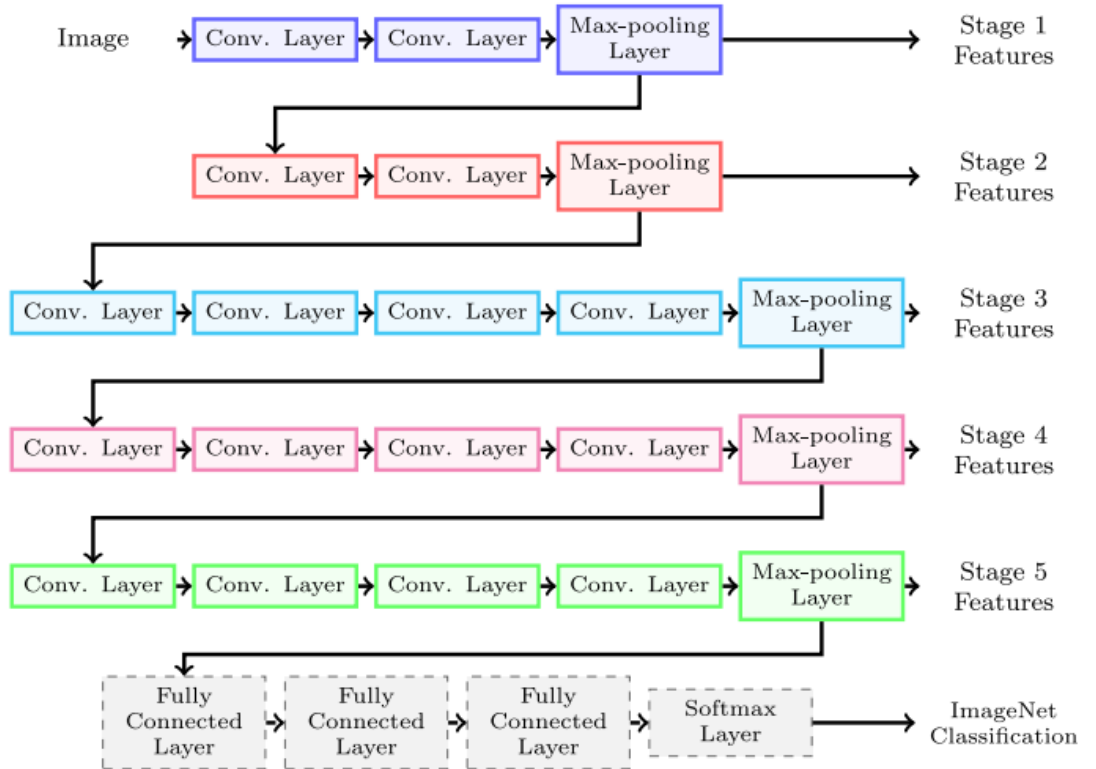
İkinci metotta ise özellik çıkarıcı olarak aynı CNN kullanılıyor. Bu sefer CNN'nin belli bir basamağına kadar olan kısmından faydalanılıyor, kalanlar ise atılıyor. Elde kalan bölümün çıktıları düzleştiriliyor, principal component analysis (PCA) ile boyutu düşürülüyor ve bir sınıflandırıcıya gönderiliyor. Bu sınıflandırıcıyı CNN'den bağımsız olarak eğitmektedir.

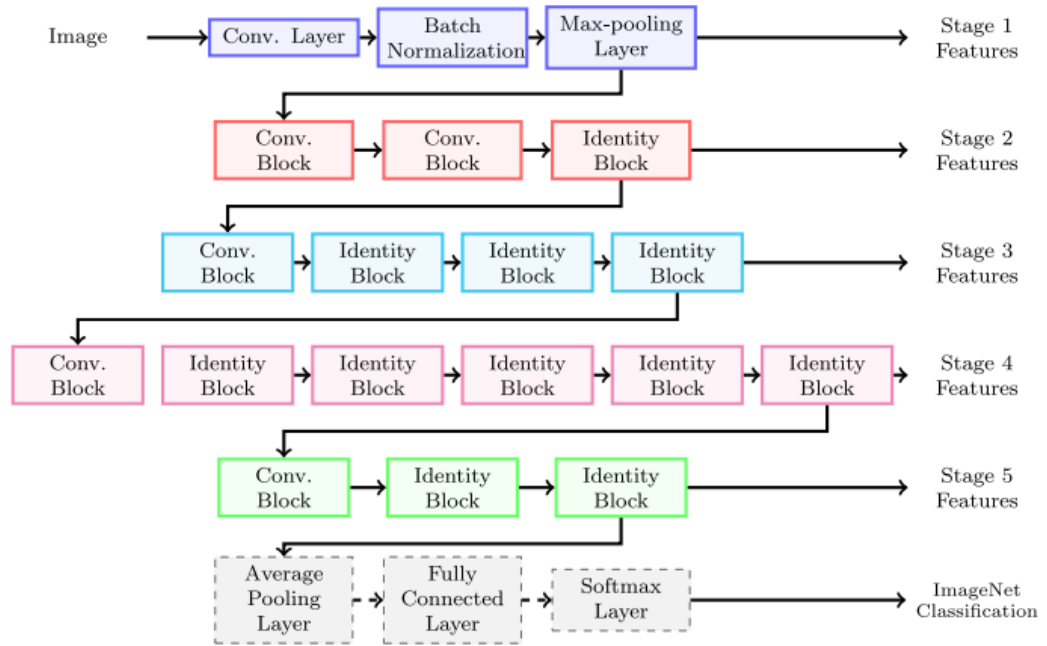
Sistemlerinde ResNet-50 ve VGG-19 mimarilerini tercih etmektedir. Seçilme sebepleri ILSVRC görsel sınıflandırma testinde benzeri sonuçlar elde etmeleri. Ancak ResNet-50 VGG-19'a nazaran biraz daha iyi sonuçlar üretmekte.

Kullandıkları yaklaşımların blok diyagramları Şekil 2.9'daki gibidir.



Şekil 2.9 – Güç hattı tespitinde kullanılmak üzere geliştirilmiş iki farklı metodun blok diyagramları





Şekil 2.10 - Sistemde kullanılan VGG-19 ve ResNet-50 tabanlı CNN mimarileri. Mimarilerin basamakları farklı renkler aracılığıyla gösterilmekte. Üstteki VGG-19, Alttaki ise ResNet-50

2.7.2. Uygulama Aşamasına Dair Detaylar

End-to-end sınıflandırma için CNN'nin son katmanı yerine binary softmax bir katman yerleştirildi ve öncelikle sadece bu katman eğitildi. Ardından figürde de görülebileceği gibi Stage 5 ve sonrasına ince ayar çekilmekte. CNN özellik sınıflandırmasında düzeltilmiş çıktılar CNN özellikleri olarak kullanıldı. Bu özellikler fazla büyük olduklarından PCA aracılığıyla boyutları 1024'e düşürüldü.

Bütün deneyler 10 katlı çapraz doğrulama aracılığıyla gerçekleştirildi. Veriseti %70'i eğitim verisi, %20'si doğrulama verisi ve %10'u test verisi olacak şekilde parçalandı. Son katmanın öğrenim katsayısı 0.1 olarak başlatıldı ve doğrulama kaybı azalmayı kestikçe yarıya indirildi. Bu işlem toplam 5 kere tekrarlandı.

İnce ayar öğrenim katsayısı da benzeri işlemlerden geçti ama 0.01'den başlatıldı. Ağırlık zayıflaması ise bütün katmanlar için 0.001 alındı.

Görsel ön işleme için iki popüler yöntem başvuruldu. Bunlardan ilki mean subtraction, ikincisi ise linear normalization.

2.7.3. End-to-End Sınıflandırma

Sistemleri için kullandıkları ILSVRC görsel sınıflandırması için önceden eğitilmiş CNN'lerin obje tespitindeki fazlalık özelleşmesinin istenen alanda performans kaybına sebep olabileceğine değinilmekte.

a) ImageNet ön eğitim ve mean subtraction ön işlemesi

	IR	VL	IR	VL
VGG-19	1.85	8.167	4.967	8.167
ResNet-50	0.65	1.0	0.25	0.267
	Trained last layer		Trained last layer & Fine-tuned Stage 5	

b) ImageNet ön eğitim ve 0-1 normalization ön işlemesi

	IR	VL	IR	VL
VGG-19	57.183	44.433	1.467	1.967
ResNet-50	0.55	4.7	0.217	0.55
	Trained last layer		Trained last layer & Fine-tuned Stage 5	

c) Rastgele ağırlıklar ve mean subtraction ön işlemesi (koyu kısımlar en iyi sonuçları belirtmekte)

	IR	VL	IR	VL
VGG-19	22.283	21.633	27.933	17.5
ResNet-50	40.517	48.983	13.333	20.5
	Trained last layer		Trained last layer & Fine-tuned Stage 5	

Şekil 2.11 - End-to-end sınıflandırma için sınıflandırma hatası yüzdeleri (a) ve (b) ön eğitilmiş ImageNet modellerini, c ise rastgele değerlerle ilklendirilmiş modele dair verileri göstermekte.

Ellerindeki eğitim verisinin kısıtlılığından ötürü modellerdeki parametre sayısını sorun çıkarmayacak seviyelere indirgemeleri gerekmektedir. Bu sebepten ötürü ince ayarı sadece son katmanla kısıtlı tutmaktalar.

(a)'da görülebileceği üzere sadece son katmanın eğitilmesiyle bile performansta ciddi artışlar gözlemlenmekte. ResNet-50 VGG-19'a göre bu aşamada çok daha iyi sonuçlar üretmekte.

Önceki deney bu sefer 0-1 normalization kullanarak tekrarlanıyor ve (b) elde ediliyor. Elde edilen bu bulgular (a) ile kıyaslanıyor. Son katmanın ince ayarından önce oldukça kötü sonuçlar elde edilse de ince ayar tamamlandıktan sonra elde edilen yeni sonuçlar (a) ile kıyaslanabilecek kıvamda oluyor.

ResNet-50					
IR	Neg	Pos	VL	Neg	Pos
False	3994	6	False	3994	6
True	9	1991	True	10	1990

VGG-19					
IR	Neg	Pos	VL	Neg	Pos
False	3836	164	False	3691	309
True	134	1866	True	181	1819

Şekil 2.12 - End-to-End sınıflandırma için karışıklık matrisleri (eğitilmiş son katman ve ince ayar çekilmiş Stage 5, ImageNet ön eğitimi ve mean subtraction ön işlemesi) Sütunlar tahminleri, satırlar ise elde edilen sonuçları göstermekte.

ImageNet ön eğitiminin elde edilen sonuçlar üzerindeki etkisini ölçmek için rastgele Xavier ilklendirmesi metodu kullanılarak rastgele ağırlıklarla ağlar oluşturulmuş. Elde edilen sonuçlara göre ImageNet ön eğitiminin sonuçlar üzerinde yadsınamayacak bir olumlu etkisi olduğu sonucuna ulaşılmış.

2.7.4. CNN Özelliklerinin Sınıflandırılması

Bu kısımda CNN'nin özellik çıkarıcı olarak kullanıldığı alternatif incelenmekte. CNN'lerin elde ettiği gösterimler ilk katmanlarda kenarlar, yuvarlaklar gibi basitken bu katmanlar ilerledikçe gösterimler daha kompleks ve soyut biçimler almaya başlar. Elimizdeki problem özelinde kompleks yapılar aramadığımızdan bu yaklaşım aleyhimize çalışabilir. Bu hipotezin test edilebilmesi için CNN'nin çeşitli adımlarından özellikler alınıp sınıflandırıcılara beslendi.

	SVM	NB	RF	SVM	NB	RF		SVM	NB	RF	SVM	NB	RF
Stage 1	12.383	29.917	26.2	4.933	35.233	24.95	Stage 1	10.07	31.183	23.4	2.717	38.233	26.733
Stage 2	7.4	28.633	24.433	1.9	37.883	26.8	Stage 2	3.95	15.65	19.267	1.7	23.483	20.317
Stage 3	2.267	14.167	18.667	1.15	27.617	20.6	Stage 3	0.833	16.733	11.85	0.883	14.733	19.167
Stage 4	0.917	17.4	16.467	2.0	30.55	21.233	Stage 4	0.417	7.767	10.417	1.67	29.917	19.3
Stage 5	0.85	21.183	11.75	2.85	30.15	21.9	Stage 5	0.417	19.75	11.1	1.083	33.483	22.417
	IR			VL				IR			VL		

Şekil 2.13 - Mean subtraction preprocessing ile CNN özellik sınıflandırması için yüzdelik sınıflandırma hataları (solda VGG-19, sağda ResNet-50 için sonuçlar)

Şekil 2.13'te gösterilen verilere göre end-to-end sınıflandırmaya benzer olarak ResNet-50 VGG-19'a nazaran daha iyi sonuçlar üretmekte. Yine önceki sonuçlara benzer

olarak IR görseller daha kolay sınıflandırılmakta. Eğer sınıflandırıcıları kendi aralarında kıyaslayacak olursak en iyi sonuçları SVM'nin ürettiği görülmekte.

IR	Neg	Pos	VL	Neg	Pos
False	3995	5	False	3978	22
True	20	1980	True	31	1969

Şekil 2.14 - En iyi CNN özellik sınıflandırması metodları için (SVM, ResNet-50, IR için Stage-4 özellikleri, VL için Stage 3 özellikleri, mean subtraction preprocessing) karışıklık matrisleri Sütunlar tahminleri, satırlar ise elde edilen sonuçları göstermekte.

Veriler üzerine konuşmak gerekirse naive Bayes ve random forest sınıflandırıcıların kullanıldığı neredeyse tüm durumlarda Stage 3 özellikleri en iyi sonuçları üretmekte. Bunların aksine SVM'nin performansı seviye arttıkça yükselmekte.


2.7.5. Çalışma Süreleri

	Stage 1	Stage 2	Stage 3	Stage 4	Stage 5	End-to-end
VGG-19	3.7	4.1	5.4	8.0	10.0	10.6
ResNet-50	2.2	7.9	11.1	16.6	19.3	21.7

Şekil 2.15 - Tek görsel için kümülatif çalışma süreleri (ms)

Şekil 2.15'te elde edilen çalışma süreleri Nvidia GTX 1080 ekran kartıyla elde edildi. En iyi sonuçları ResNet-50 ile çalışan end-to-end sınıflandırma 21.7 ms ile verdi. SVM, NB ve RF aracılığıyla PCA gösterimin çalışma süreleri 0.5 ms'nin altında olduğundan ve sonuçları etkilemediğinden atlanmış. Sistemin çalışma süresini daha da düşürmek için MobileNets gibi hafif mimariler kullanılabilir, eldeki mimari kırılabilir veya özelleştirilmiş donanımlardan faydalanılabilir.

2.7.6. Güç Hattı Algılamaya Dayalı Metodlar




Şekil 2.16 - İlk satır end-to-end yaklaşım ile güç hattı olmadığı farkedilmiş örnekleri içermekte. Diğer satırlar ise sırasıyla EDLines, LSD ve Hough Transform'a dayalı bir metod ile tespit edilmiş çizgi segmentlerini içermekte.

Eldeki yöntemler genellikle sahnedeki çizgiye benzer şekillerin tespitine dayanmakta. Bu aşamada çizgi segmenti tespiti metodlarının güç hattı tespitindeki performansları ölçülmekte.

Sahne herhangi bir güç hattı bulunmadığında elde edilen sonuçlar Şekil 2.16'da ele alınmakta. EDLines ve LSD'nin yer yer sıradan çizgi şeklindeki cisimleri ya da paralel yapıları bazı çizgi şeklindeki cisimler sebebiyle hatalı sonuçlar ürettiği gözlemlenmekte. Hough Transform'a dayalı metodlar ise daha da fazla probleme sebep olmakta. Çünkü görselin içinde belli bir miktarda çizginin bulunduğunu varsaymaktalar. Bu sebepten ötürü sistemde kullanılmaları imkansız.

Bunun ardından Şekil 2.17'de görülebileceği gibi eldeki sistemin yanıltıldığı durumlarda diğer sistemlerin nasıl sonuçlar ürettiği incelenmekte. Hatların arkaplanın içine karıştığı bu durumlarda diğer kenar tespit yöntemlerinin de başarısız sonuçlar ürettiği gözlemlenmiştir.



Şekil 2.17- İlk satırda 4'er tane güç hatlı ve güç hatsız örnek bulunmakta. End-to-end metod bu örnekleri doğru sınıflandırmayı başaramadı. Elde edilen çıktılar 2. Satırda görülmekte. Sonraki satırlar ise EDLines, LSD ve Hough Transform'a dayalı metod ile elde edilen çıktıları göstermekte.

	Proposed Methods	Error (%)
IR	End-to-end CNN classification (ResNet-50, ImageNet pre-training, fine-tuned Stage 5, 0-1 normalization preprocessing)	0.217
	CNN features + Support Vector Machine (ResNet-50, Stage 4, ImageNet pre-training, mean subtraction preprocessing)	0.417
	DCT features + Random Forest (128×128 descriptors, classical selection) [18]	3.75
VL	End-to-end CNN classification (ResNet-50, ImageNet pre-training, fine-tuned Stage 5, mean subtraction preprocessing)	0.275
	CNN features + Support Vector Machine (ResNet-50, Stage 3, ImageNet pre-training, mean subtraction preprocessing)	0.883
	DCT features + Random Forest (128×128 descriptors, classical selection) [18]	14.6


Şekil 2.18 - IR ve VL için en iyi sonuçları üreten yaklaşımlar

2.7.7. Görselleştirme

Eldeki metodun daha da detaylı analizi için pozitif örneklere dair belirginlik haritaları oluşturuldu. Bu haritaları elde etmek için guided backpropagation kullanılmakta. Bu yaklaşım gövdeden ziyade dış hatlara odaklandığı için isteneni elde etmeye oldukça elverişli. Şekil 2.19’da elde edilen belirginlik haritaları görülebilmekte. Eldeki sistem sadece çizgi şeklindeki hatları algılayabilen sistemlerin aksine eğri halindeki kabloları da algılayabilmekte. Bir diğer ilgi çekici durum ise eldeki sistemin elektrik direkleri ile güç hatları arasındaki ilişkiyi fark etmiş olması.

Binalara ve diğer yapılara dair çizgi şeklindeki hatları sistem istendiği gibi gözardı etmekte.

Son olarak bu haritaların pilota görsel geri dönüş sağlamak için kullanılabileceği de göz önünde bulundurulmalı.



Şekil 2.19 - İlk sırada girdiler, ikinci sırada belirginlik haritaları, son sırada ise pilota görsel geri dönüş sağlayabilecek görsellemeler bulunmaktadır

2.8. Otonom Hareketli Robotlar için Hızlı ve İsabetli İnce Yapılı Nesne Algılama [8]

2.8.1. Giriş

Telleri kablolar ve ağaç dalları gibi ince yapıları tespit etmek geçmişte gözden kaçsa da şimdi çok önemli. LIDAR, RADAR ve stereo kameralar gibi aktif sensörlerle ince objelerin tespiti oldukça zor. Bu çalışmada ince engel tespiti için video sekansları kullanılması önerilmiş. Video karelerindeki kenarlı engeller belirleniyor ve kenar bazlı görsel odometre teknikleriyle 3D ortamda yeniden oluşturuluyor. Hem monoküler hem

de stereo kameralar için çözümler sunulmuş. İlki ölçek belirsizliğini çözmek için Inertial Measurement Unit (IMU) verisi barındırırken, diğeri yeni ve tamamen görüş tabanlı bir çözüm kullanıyor. Deney sonuçlarında metotların hızlı çalıştığı ve farklı koşullar altında sağlam ve isabetli şekilde ince engel tespiti yaptığı görülmüş.

Kenar belirlemede üç hedef seçilmiş:

- Engel Tanımlama: Engelin kenarları çıkarılmalı ve objenin kaçırılmaması için tam olmalı.
- Derinlik Dönüşü: Kenarların 3 boyutlu koordinatları elde edilmeli ve engelden kaçınılması için yeterli olmalıdır.
- Verimli Çözüm: Algoritma, yerleşik bir şekilde gerçek zamanlı ve limitli hesaplama gücüyle çalışırken verimli olmalı.

Sistemleri büyük ve üstünde kenarlı dokuları olan engelleri de fark edebiliyor fakat büyük, dokusuz veya şeffaf engelleri fark edemese de bu sorun sonar gibi aktif bir sistemle çözülmüş

Sistem, bir TurtleBot üstündeki yerleşik 1.5GHz 4 çekirdek Celeron işlemcili bilgisayarda, 640x360 stereo görüntü çifti sekanslarını 17 fps te işlemiş.

2.8.2. Diğer Çalışmalar

Görüş bazlı engel tespit yöntemleri genelde tek veya iki kamerayla çalışmakta. Tekli kamera metotları genelde görüntü işlemeyle çalışan ve tek kamerayla üçgenleme yaparak derinlik tahmini yürüten sistemler ve bunların çalıştırılabilmesi için bir GPU ya ihtiyaç var. Küçük sistemlerde yerleşik bir GPU bulundurmak oldukça zor bu yüzden bu sistemler normal boyutta araçlarda (helikopter, otonom araçlar, vb.) kullanılmakta.

Çift kameralı sistemler ise en çok otonom araçlarda sürüş esnasında yol takibi ve normal boyutta engellerin tespitinde kullanılırken oldukça yüksek hesaplama gücü kullanmakta. UAVlerde bu sistemleri kullanabilmek için bazı şeylerden ödün vermek gerekmektedir. Örnek olarak mobil bir CPU üstünde yüksek kare hızlarına ulaşabilmek için sadece sabit eşitsizlikler eşleştirilmeli ve bu ölçümler birbirine süpürgeyle ittirilir gibi birleştirilmeli.

2.8.3. Görüş Bazlı İnce Engel Tespiti

Engel tespiti üç ana adımda gerçekleşiyor: kenar çıkarımı, kenar 3D yapılandırma ve kenar derinliği haritalarında engel etiketlemesi.

Notasyonlar: Bir kenar pikseli bir tuple olarak $e = \{p, g, d, \sigma\}$ olarak gösteriliyor. p , görüntü kenar koordinatıyken g kenar gradyanı. d bir kenarın *ters* derinliğini belirtir ve σ ters derinliğin varyansını temsil eder.

Mevcut çerçeveye yeni çerçeve arasındaki dönüş $w \in so(3)$ ve kayma $v \in R^3$ olarak belirtilmiş. $R = \exp(w) \in SO(3)$ dönüş matrisini belirtir. Euclid dönüşümünün basit bir gösterimi için 6 boyutlu bir vektör $\xi = \{w, v\} \in se(3)$ kullanılmış. π , kamera koordinatındaki 3D noktayı görüntü koordinatına yansıtan fonksiyonu belirtmiş.

2.8.3.1. Monoküler İnce Engel Tespiti

Bu metotta tek kameralı bir sistem kullanıldığından ölçek belirsizliğini çözebilmek için IMU verisi kullanılmak zorunda. Stereo kameralı metotta IMU verisine ihtiyaç yok.

2.8.3.2. Kenar Çıkarımı

DoG (difference of two Gaussians) dedektörü ile Canny-style hypothesis linking adımının kombinasyonunu kullanılması önerilmiş. İyi tekrarlanabilirliğinden dolayı DoG dedektörü seçilmiş. Hypothesis link adımı, ince objelerdeki bolca zayıf kenarın geri dönümü için kullanılacak. Ayrıca kenar tespiti için de daha agresif bir eşik değeri sağlıyor: deneylerde %10 ila %20 arasında daha az kenar çıkarırken ince engel tespiti sonuçlarını etkilemiyor, böylece verimlilik artıyor.

2.8.3.3. 3B Kenar Oluşturma

Kenarları çıkardıktan sonra, bir sonraki adım bu kenarları 3D de yeniden oluşturup derinliklerini tahmin etmek. Oluşturma metodu hali hazırda olan bir VO (Visual Odometry) algoritması kullanılarak yapılmış. Bu VO sistemi, mevcut karenin yerel ters derinlik haritasıyla, Gaussian dağılımıyla belirtilen her kenar pikselinin ters derinliğini saklıyor. Yeni bir kare geldiğinde kamera hareketi, mevcut karenin kenar haritası yeni karenin kenar haritasına uydurularak takip ediliyor. Özellikle, bir sonraki geometrik falso minimize ediliyor:

$$E_o(w, v) = \rho((W(p_i, d_i, \xi) - \bar{p}_i) \cdot \bar{g}_i) \quad (2.1)$$

buradaki W , p_i kenar pikselini bir sonraki kareye yansıtmak için görüntü koordinatı p_i 'yi, ters derinlik d_i 'yi ve iki kare arasındaki dönüşüm $\xi \in se(3)$ yi alan çarpıtma (saptırma, sektirme) fonksiyonudur.

p , bir sonraki karedeki karşılık kenardır ve p_i 'nin gradyent yönü ile \bar{p}_i 'nin gradyent yönü olan \bar{g}_i 'nin karşılıklı aramasıyla bulunur. Haritalama da yeni kenar haritasından eskisine epipolar arama ile yapılır. Bu arama normalde iki kameralı sistemlerde kullanıldığından ve bu sistem tek kameralı olduğundan arama sonuçlarını işlemek kameranin konum bilgilerine ihtiyacımız var. Bu da IMU dan elde ediliyor. Mevcut karenin ters derinlik haritası kameranin hareketi kullanılarak yeni kareye yayılır ve epipolar aramadan elde edilen yeni bulgularla güncellenir. Bu veri bir EKF (Extended Kalman Filter) hareketiyle birleştirilir. İlk denkleminizden gelen değişim dönüşümler ile birleştirilerek tam bir örtüşme sağlanır:

$$E(\mathbf{w}, \mathbf{v}) = E_0(\mathbf{w}, \mathbf{v}) + \lambda_w \|\mathbf{w} - \mathbf{w}_0\|^2 + \lambda_v \|\mathbf{v} - \mathbf{v}_0\|^2 \quad (2.2)$$

2.8.3.4. Kenar Derinlik Haritalarında Engel Etiketleme

Etiketleme işleminde başka metotların ham derinlik haritaları genellikle gürültülüdür ve post-processing gerektirir. Güçlü bir engel etiketlemesi için sadece bir çok karede eşleştirilmiş kararlı derinlik tahminleri bulunan kenar pikselleri dikkate alınmış. Genelde derinlik haritasına dağılmış gürültülü kenarları incelerken, etiketlenmiş küçük bağlı parçalar üstünde bir filtreleme yapılmış. Verimlilik için filtreleme, eğer etiketli kenarlar bir alt eşik değerinin altında ya da üst eşik değerinin üstüneyse yapılıyor.

Algorithm 1 Obstacle Edge Pixels Labeling

Input: List of edges $e_i = \{\mathbf{p}_i, d_i, \sigma_i, t_i\}$,
 Thresholds $\sigma_{th}, t_{th}, cnt_l, cnt_h$, Obstacle Space Volume \mathbf{S}
Output: List of obstacle edgel labelings \mathbf{O}
 $cnt \leftarrow 0$
for each edge pixel e_i **do**
 if $\sigma_i < \sigma_{th}$ and $t_i < t_{th}$ and $\pi^{-1}(\mathbf{p}_i, d_i) \in \mathbf{S}$ **then**
 $o_i = true$ ▷ The i th edgel labeled as obstacle
 $cnt \leftarrow cnt + 1$
if $cnt \in [cnt_l, cnt_h]$ **then**
 $\mathbf{O} \leftarrow \text{FILTERSMALLCONNECTEDCOMPONENTS}(\mathbf{O})$
return \mathbf{O}

Şekil 2.20 - FILTERSMALLCONNECTEDCOMPONENTS işlemi, engel olarak etiketlenmiş küçük bağlı parçaları listeden çıkarıyor.

2.8.3.5. Stereo İnce Engel Tespiti

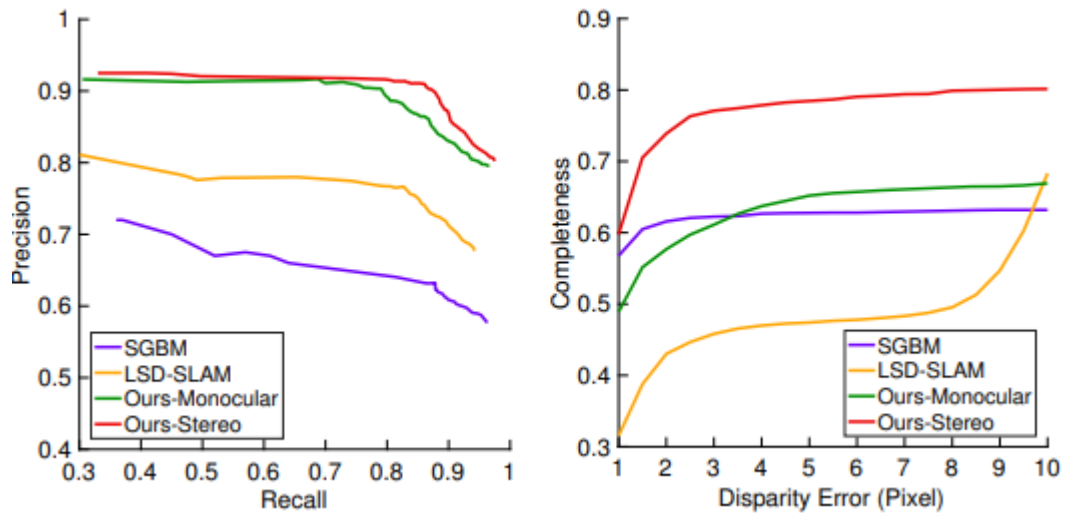
Çift kamerayla yapılan işlemler tek kameradaki gibi 3 adımdan oluşuyor ve ilk adımla son adımın işleyişi tamamen aynı. 2'inci adım da ise çift kamera kullanıldığından epipolar işlemlerle hata düzeltmeye gerek kalmadan derinlik haritası çıkarılıp 3D kenarlar oluşturulur.

2.8.4. Engel Tespit Sistemi

Kullanılan ince kenar tespit sistemiyle birlikte sonar sensörleri paralel olarak çalıştırılıp engel tespiti ve kaçınmasında kullanılır.

2.8.5. Deneyler

Tekli ve çiftli kamera kurulumları bir arada temel metot olarak OpenCV'nin Semi-Global Block Matching (SGBM) metodu ve Large-scale direkt monoküler SLAM (LSD-SLAM) metotları karşılaştırıldı.



Şekil 2.21 - Nicel Sonuçlar. Soldaki şekil algılama algoritmamızın precision-recall eğrisi ve sağdaki şekil tamlık ölçüsünü gösterir.

Deneyler sonucunda stereo metot kesinlik ortalamasında en yüksekte. Ardından monoküler, LSD-SLAM ve SGBM takip ediyor. Mono ve stereo 0.75 recall değerine kadar nerdeyse kafa kafaya olsa da monokülerin keskinliği azalmaya başlıyor. Tamlık değerlerinde ise LSD-SLAM bütününün çok altında. Monoküler metot 3 eşitsizlik sapmasına kadar SGBM'in altında kalmış, stereo metot ise bütün değerlerde en üstte seyretmiş.

	SGBM	LSD-SLAM	Ours- Monocular	Ours- Stereo
640×480	4.97	14.26	37.56	17.59
1280×720	1.12	8.73	12.65	5.26

Şekil 2.22 - Hız Karşılaştırması (fps cinsinden). 1.5GHZ dört çekirdekli Celeron yerleşik CPU üzerinde ölçüldü.

Kare hızlarına bakıldığında SGBM çok düşük performans göstermekte. 480p çözünürlükte LSD-SLAM kabul edilebilir sayılar gösterse de monoküler ve stereo metotlara göre düşük. Hem monokülerin hem de stereo metotların performansları çözünürlük 720p'ye çıktığında yaklaşık üçte bir kadar azalmış.

2.9. Optik Görüntülerden Elektrik Teli Algılanması [9]

Bu yazıda lazer, kızılötesi veya elektromanyetik sistemlerden faydalanılmayarak sadece görüntü işleme sistemleri kullanılacaktır. Bunun gerekçesi olarak bu sistemlerin enerji harcaması, boyutları ve hava aracındaki yükünün fazlalığı belirtilmiştir. Tel algılama için özelden genele işleyen bir algoritma önerilmiştir. Bu algoritmanın kullanacağı kenar algılama metodu geleneksel metotlardan farklı olarak baştan tasarlanmış olup, sadece simetrik kenarları algılamaya odaklıdır. Böylece köşeye sahip kenarları algılamayacaktır. Bu sistem hatalı pozitifleri ayıklamayı kolaylaştıracaktır. Bunun yanı sıra sistem elektrik teli kesitlerinin birleştirilmesinde kullanılan eşitlik çoğu algoritmanın birinci dereceden polinomunun aksine ikinci derecedendir. Böylece eğimli tellerin tespiti hedeflenmektedir.

Kenar algılama için normalde hazırda bulunan kenar algılama algoritmaları kullanılmaktadır. Bunlar arasında Canny algoritması ve diğer çalışmaların algılayıcıları vardır. İki sınıfa ayrılacak olan kenar algılama işlemi, simetrik veya köşe bölgesi olarak ayrılır. Simetrik kenarların Gauss türünde bir şekle sahip olduğu ve tepe noktasından simetrik olduğu belirtilmiştir. Ancak bahsedilen kenar algılama yöntemleri simetrik olma durumunu ölçmemekte, bu sebeple hatalı pozitifler üretmektedir. Küresel açıda yapılan kenar algılama sürecinde simetri tespit etmek zorlayıcı bir işlemdir. Bu yazıda kullanılacak tel kesiti algılama yöntemi, FDOG tabanlı bir Eşlenmiş Filtre (MF) üzerine tasarlanmıştır.

Normalde insan damarlarının tespiti gibi benzer, tel yapısındaki nesnelerin tespitinde kullanılan MF bu işlem için etkili bir yöntemdir. Farklı çalışmalarda da kullanılan, MF ile FDOG sisteminin birleşimi olan MF-FDOG adlı bir sistem kullanılacaktır. Bu yöntem doğrudan tel algılamada kullanılamaz; bu sebeple sistemin üstüne tel yapısına özel bir filtre uygulanarak elektrik teli harici tespitler olabildiğince elenecektir. Bu sayede tel kesitleri elde edilmiş olacaktır.

Normalde tel kesitlerini paralellik gibi yapısal özellikleri ile bir araya getiren sistemler, telin eğrisel yapıda olma ihtimalini hesaba katmamaktadır. Bu yazıda, yolların uydudan algılanması, vücut taramasında damar gibi silindirik yapıların bulunması gibi alanlarda kullanılan çizge teorisi yaklaşımı kullanılacaktır. Bu sistem görselin her bir pikselini grafik üzerindeki bir nokta olarak alacak, kesitleme sorununu böylece bu noktaların ön plan (tel yapısal özellikleri) ve arkaplan nesneleri şeklinde ikili bir sınıflandırmaya sokarak çözümleyecektir. Ancak yol kıyaslamasının ikilik karşılaştırma sistemi tel algılamada yeterli değildir, bu sebeple çoklu bir karşılaştırma sistemi kullanılmalıdır. Çoklu karşılaştırmada kullanılacak özelliklerin bilinmemesi bu yöntem için büyük bir zorluk çıkarmaktadır. Çizge Teorisinin bu alanda iki dezavantajı vardır; işlem yükü ve parçalar üstünde grafik işleme için gerekli algoritmaların bulunmaması. Buna rağmen eğik teller ile lineer tellerin birleştirilmesi bu çalışmada ana hedef olarak belirlenmiştir.

Sistemin denemeleri için USF Veri Setinin yanı sıra Beijing’de 2010’da elde edilen 0.5 fps hızındaki bir video görüntüsü kullanılmıştır. Deneylerde çeşitli arkaplan gürültüsü, farklı mesafeler ve perspektif, değişken hava şartları ve kara şartlarına önem verilmiştir. Performans ölçümü için doğru ve hatalı algılamalar kıyaslanmıştır. Elde edilen sonuçlara göre örnek alınan çalışmaların iki katı ile %91.95 doğru pozitif algılaması yapılmıştır. Yanlış pozitif oranı %38.96 ile bu çalışmaların üçte birine inmiştir. Sistemin çalışma süresi 1 saniyeyi aşmış, bu sebeple gerçek zamanlı çalışma için uygun olmadığını göstermiştir. Bu sorunun daha güçlü bir bilgisayar ile çözülebileceği vurgulanmıştır. Hatalı pozitif sayısını azaltmak için tel özelliklerinin daha fazlasından faydalanılması önerilmiştir.

2.10. Hava Araçları için Tel ve Kablo Tespit Sistemi [10]

Döner kanatlı hava aracı pilotlarının tellere takılmadan uçuşlarını sürdürebilmeleri için telleri bir şekilde fark etmeleri gerekmekte. Mevcut durumda da hava araçlarını uyarmak maksadıyla yüksek gerilim hatlarının görülebilmesi için, iki renkli ve yaklaşık 4 kilogram ağırlığında alüminyum küreler hatlar üstüne belli aralıklarla yerleştirilmekte. Bu küreler gün içinde fark edilseler de gece veya zorlu hava koşullarında oldukça zor fark edilmekte. Bunun için telleri görüntüleyip algılayacak bir sistem kullanılmalıdır.

Şu ana kadar sunulmuş bir çok çizgi bölütleyicisinden biri olan LSD'ye göre mevcut bilgisayarlarda 11 kat daha hızlı çalışan EDLines çizgi bölütleyici ve tespit edicisi kullanılması önerilmiştir. Bu yöntem bağlantılı piksel zincirleri üretmekte ve üretilen zincirin Helmholtz prensibine göre çizgi doğrulamasını yapmaktadır.

2.11. Karar Matrisi ve Seçilen Yöntem

Yapılan literatür taraması sonucunda araştırma amacına uygun 10 sistem bulundu ve detaylıca gözden geçirildi. İncelemenin ardından hazırlanan bir karar matrisi ile bu sistemler belirlenmiş kriterler çerçevesinde karşılaştırıldı.

Tercih edilen ilk yöntemin Tablo 1'de görülen Ref – 1 [1] olmasına karşın uygulama açısından mümkünlik, daha geniş bir veri setinin bulunması ve performans açısından daha iyi sonuçlar alınacağı düşünüldüğünden bu yöntemin yerine Ref – 7'deki [7] yaklaşımın kullanımında karar kılındı.

Tablo 2.1 - Yöntemlerin kıyaslanması için kullanılan Karar Matrisi

	Kabloların hava aracı tarafından en az 15 metrelik bir mesafeden görünebilmesi	Gerçek zamanlı çalışması	İmplementasyon kolaylığı	Derin öğrenme kullanımı	Kabloların Üç Boyutlu Yapılandırılması	Yazılım odaklı olması	Kötü hava koşullarında verimli olması
Ref - 1	✓	✓	✓	✓	✓	✓	✗
Ref - 2	✗	✓	✓	✓	✗	✓	✗
Ref - 3	✓	✓	✗	✗	✗	✓	✗
Ref - 4	✓	✓	✗	✗	✗	✗	✗
Ref - 5	✓	✓	✗	✗	✗	✗	✗
Ref - 6	✗	✓	✓	✓	✓	✓	✗
Ref - 7	✗	✓	✓	✓	✗	✓	✗
Ref - 8	✗	✓	✗	✗	✓	✗	✗
Ref - 9	✗	✗	✓	✗	✗	✓	✗
Ref - 10	✗	✓	✗	✓	✗	✓	✗

	Sistemin kabloları tespit mesafesi	Sistemin çalışma hızı	İmplementasyon aşamasında sorun çıkaracak etmenler	Sistemin derin öğrenme kullanması	Kabloların Yapılandırılma Şekli	Sistemde kullanılan donanım	Sistemin zorlu hava koşullarında verdiği sonuçlar
Ref - 1	1000m	Gerçek Zamanlı	Model Eğitimi	Var	3B	Kamera (Tekli)	Veri yok
Ref - 2	Veri yok	Görsel Üzerinden	Model Eğitimi	Var	2B	Kamera (Tekli)	Veri yok
Ref - 3	20m	Gerçek Zamanlı	Pahalı Donanım	Yok	2B	Kamera (Tekli)	Veri yok
Ref - 4	701m	Gerçek Zamanlı	Pahalı Donanım ve Eski	Yok	2B	Kamera (Tekli) + LIDAR	Fazlasıyla olumsuz [4]
Ref - 5	500m	Gerçek Zamanlı - 10Hz	Pahalı Donanım	Yok	2B	Kamera (Tekli), MMW ünitesi ve GPS	İddialarına göre iyi, kanıt yok
Ref - 6	Veri yok	Gerçek Zamanlı	Model Eğitimi	Var	3B	Kamera (Tekli)	Veri yok
Ref - 7	Veri yok	Gerçek Zamanlı	Model Eğitimi	Var	2B	Kamera (Tekli)	Veri yok
Ref - 8	3m	Gerçek Zamanlı 17fps	Açık Alanda Çalışmaya Uygun Değil	Yok	3B	Kamera + IMU + Sonar	Veri yok
Ref - 9	Veri yok	Gerçek Zamanlı	Model Eğitimi	Var	2B	Kamera (Tekli)	Veri yok
Ref - 10	Veri yok	Gerçek Zamanlı	Model Eğitimi ve Eski	Yok	2B	Kamera (Tekli)	Performans çok düşmekte

3. MATERYAL VE YÖNTEM

Kullanılan yöntem üç aşamada uygulandı. İlk aşamada VGG19 ile model eğitimi sağlandı. Sonrasında eğitilen model sabit, hareketsiz kareler üstünde test edildi. Son olarak gerçek zamanlı performansın ölçülmesi için model video üzerinde uygulandı.

3.1. Kullanılan Veri Seti

Modelin eğitim aşamasında kullanmak için; yarı yarıya içinde tel görüntüsü bulunduran 4000 görselden oluşan, [7] çalışmasında da kullanılan veri seti kullanıldı. Bu veri setinden bazı örnekler Şekil 3.1’de görülebilir. Veri setinin rastgele seçilen %20’lik kısmı daha sonra modeli test etmek üzere ayrıldı.



Şekil 3.1- İlk ikisi tel bulunduran, son ikisi bulundurmayan örnekler [7].

Bunların yanı sıra çevrimiçi elde edilen videoların birleştirilmesi ile test işlemlerinde kullanılması amacıyla ayrı bir veri seti oluşturuldu. Bu videolar inşaat alanı çevresinde ve doğal alanlarda drone’lar tarafından çekilen, bünyesinde belirli zamanlarda tel bulunduran görüntülerden oluşmakta.

Hem video hem hareketsiz görüntülerin seçimi sırasında dikkat edilen kriterler, veri setinin dengeli, çok boyutlu ve gerçek hayat senaryolarını yansıtan görsellerden oluşmasıydı. Bu amaçta veri setinin hem arkaplanı basit, tel algılaması kolay görselleri hem de elektrik tellerini anımsatacak ince çizgiler gibi karmaşık yapılar bulunduran, arkaplanı karmaşık ve mesafenin fazla olduğu görselleri bulundurmasına özen gösterildi.

3.2. Kullanılan Yöntemin Açıklaması

Kullanılan yöntem üç aşamadan oluşmaktadır. Bunlar; modelin çalışma prensibi, sabit görsel üstünde eğitilip test edilmesi ve son olarak gerçek zamanlı denenmesidir.

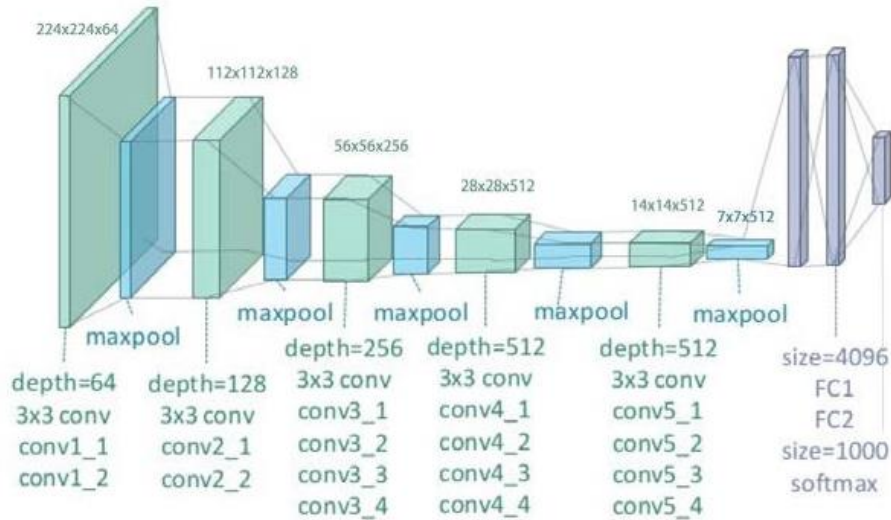
3.2.1. Modelin Çalışma Prensibi

Sistem [7]'de görüldüğü gibi VGG19 modeli üzerine kurulmuştur. Bunun sağlanması için Transfer Learning yöntemi kullanılacaktır. Transfer Learning, var olan bir modelin başka bir alanda kullanılma amacıyla, yeni parametreler ile tekrar kullanımıdır. Bu çalışma özelinde sözü geçen model VGG19 olacaktır.

VGG19 modeli, bir öncü model olan VGG16 üzerine üç konvolüsyon eklenerek elde edilmiştir. VGG16 kendi bünyesinde 13 konvolüsyon katman, üç tam bağlantılı katman olacak şekilde 16 katman bulundurup ismini bundan almaktadır. Benzer şekilde eklenen üç konvolüsyon katmanı ile VGG19 ortaya çıkar. Eklenen katmanlar sayesinde VGG19 daha az eğitim verisi kullanarak daha yüksek doğruluk oranı ve daha hızlı bir eğitim süreci ortaya koymaktadır.

VGG16 gibi VGG19'un konvolüsyon katmanları 3x3'lük bir filtre boyutu, tek adımlık kaymalar ve same padding'e sahiptir. Max-pooling katmanlarında ise 2x2'lik filtreler ve iki adımlık kaymalar bulunur. VGG19 mimarisinin çalışma şekli Şekil 3.2'de gösterilmiştir.

2Conv — 1Maxpool — 2Conv — 1Maxpool — 4Conv —
1Maxpool — 4Conv — 1Maxpool — 4Conv —
1Maxpool — 1FC — 1FC — 1FC



VGG-19 Architecture (Image source: researchgate.net)

Şekil 3.2- VGG19 Mimarisi

VGG19 modelinin kendi halinde vereceği performansın ölçülmesi adına tek başına bir denemeye tabii tutulmuştur. Bu amaçla hazırda bulunan modelin Transfer Learning ile eğitilecek modele eklenmesi sonucu modelin ezber yaptığı gözlemlenmiştir. Derin öğrenme alanında ezber, modelin görseldeki özellikleri okumayı bırakıp algılanan parazit ve gereksiz değişiklikleri hesaba katarak son tahmini olumsuz etkilemeye başlamasıdır.

Ezberin önüne geçmek için hazır VGG19 modelinin üstüne ilk olarak Flatten katmanı ve 0.8 değerinde bir Dropout katmanı eklenmiştir. Bunun üstüne relu aktivasyonu ile 512'lik bir Dense katmanı, yeniden 0.8 değerinde Dropout ve softmax aktivasyonu ile 2'lik bir Dense katmanı eklenerek model tamamlanmıştır.

3.2.2. Sabit Görseller Üzerinde Test

Model eğitilirken veri setinden %20'lik bölüm test için, %80'lik bölüm eğitim için ayrılmıştır. Test için kullanılan veri sonradan eğitilen modelin testi için tekrar kullanılmıştır. Bunun yapılmasının sebebi ise, halihazırda etiketlenmiş veriden faydalanarak test ile modelin performansının isabetli bir şekilde ölçülebilmesidir.

Modelin test sürecinde çalışma süresini ölçmek için uygulamalar yapılmıştır. Uygulanan testler sonucunda modelin performansı, çalışma süresi ve doğruluk oranının istenen kriterleri karşılama durumu gözlemlenmiştir. Tablo 3.1'de test sonucunda elde edilen performans ölçütleri görülmektedir.

Tablo 3.1- Test Sonucunda Performans Ölçütleri

METRİKLER	800 TEST KARESİ
ACCURACY	0.9512
PRECISION	0.9728
RECALL	0.9336
F1 SKORU	0.9528

Test sürecinde öncelikle test verisindeki 800 görsel model ile tahminden geçirilip asıl sonuçlarla bu tahminler kıyaslanmaktadır. Çıkan sonuçların verisi elde edilip, yanlış sonuç veren görseller daha sonra incelenmek üzere çıkartılmaktadır. Görsellerin sınıflandırılması Doğru Pozitif (TP), Yanlış Pozitif (FP), Doğru Negatif (TN), Yanlış Negatif (FN) şeklinde yapılmıştır.

3.2.3. Video Üzerinde Test


Bu testin asıl amacı, modelin gerçek hayat koşullarında ve gerçek zamanlı olarak çalışma performansını ölçmektir. Veri seti çevrimiçi elde edilen video görüntülerinden oluşturulmuştur. Test boyunca ortalama FPS kaydedilerek modelin gerçek zamanlı performansı ölçülmüştür. Aynı zamanda modelin tahminlerinin özgüveni de kaydedilmiştir.

Sabit görseller ve video üzerinde yapılan testlerden elde edilen veriler hakkında yapılan çıkarımlar, araştırma sonuçları bölümünde paylaşılacaktır.

4. ARAŞTIRMA SONUÇLARI



İlk eğitim, üzerinde oynanmamış VGG19 ile yapıldığından kesinlik %100'e çok yakındı yani model veriyi ezberlemekteydi. Ezberlemenin önüne geçmek ve daha iyi performans alabilmek için modele önceden bahsedilen eklemeler ve düzenlemeler yapıldı. Bu değişikliklerden sonra yapılan eğitimle elde edilen model Tablo 4.1'deki kesinlik sonuçlarına sahipti. Eğitim sonucunda modelin kesinliği %92,69 olarak kaydedildi.

Tablo 4.1- Üretilen modelin kesinlik grafiği



Eğitilen modelin 800 adet test görseli üzerinden elde edilen deney sonuçları Tablo 4.2'deki gibidir. Model %95.12 oranında doğru tahminlerde bulunmuş; %1.37 Yanlış Pozitif, %3.50 Yanlış Negatif sonuç vermiştir. Sistemin çalışması 61.67 saniye sürmüştür. Bu demektir ki elde edilen sistem saniyede 13 görseli işleminden geçirmiştir. Video üzerinde yapılan deneylerde de benzer sonuçlar elde edilmiştir.

Tablo 4.2- Modelin test verisi üstündeki sonuçları



Şekil 4.1- Modelin FN ya da FP sonuç verdiği örnek görseller (İlk 6 görsel FN, son 2 görsel FP)

Model, Şekil 4.1’de görüldüğü gibi en çok arkaplan gürültüsünden, kontrast düşüklüğünden ve hat benzeri farklı şekillerin varlığından olumsuz etkilenmektedir. Benzer şekilde olumsuz hava koşulları ve mesafe de modelin doğruluk oranını azaltmaktadır.

Video üzerinde yapılan testlerde benzer sonuçlar alınmıştır. Şekil 4.2’de görüldüğü gibi yüksek arkaplan gürültüsü, mesafe ve ışıklandırma koşulları tahminleri olumsuz etkileyebilmektedir. Algılanan telin var olma olasılığı 0.74 gibi düşük bir değerdir.



Şekil 4.2- Video üzerinde düşük olasılıklı doğru pozitif

Şekil 4.3'te modelin gürültülü ortam, düşük çözünürlük ve kontrasttan etkilenerek hatalı bir tespit yaptığı görülmektedir. Tel olmadığını belirtip %55 olasılık göstermiş olması, modelin tel olup olmadığı konusunda kararsız olduğunu belirtmektedir.



Şekil 4.3- Video üzerinde Yanlış Negatif (Kararsızlık)

Şekil 4.4'te model benzer bir şekilde düşük kontrast ve arkaplan gürültüsü sebebiyle tel algılamakta zorluk yaşamış, kararsızlıkta kalmıştır.



Şekil 4.4 - Yanlış negatif, kararsızlık durumu

5. TARTIŞMA

Bu çalışma boyunca VGG19 modelinin transfer learning ile üstüne katman eklemeleri yapılarak tel algılama alanında kullanılabilir hale getirildi. Ortaya çıkan model test edilip çıktıları değerlendirildi. Sonuç olarak gerçek zamanlı çalışabilen, özellikle hareketsiz görsellerde olumlu sonuçlar veren bir model elde edildi.

Beklendiği üzere model tipik görüntü işleme sorunlarıyla yüzleşti. Yüksek arkaplan gürültüsü, düşük kontrast, uygunsuz hava koşulları, tespit mesafesi ve ışıklandırma gibi etkenler modelin çalışmasını piyasadaki benzer yaklaşımlar gibi olumsuz etkiledi. Bunlara karşın model çok düşük bir maliyetle gerçek zamanlı olarak tatmin edici sonuçlar elde etti.

Bu projenin geliştirilmesi ve eksikliklerinin giderilmesi için yapılabilecek eklemelerden bazıları; sistemin nesne algılama yöntemleri ile tellerin konumunu tespit edebilmesi, bu tespitlerin vektörel uzayda yapılması gibidir. Bunun yanı sıra ResNet gibi farklı mimariler ile de algılama denemeleri yapılabilir. Aynı modelin daha iyi performans vermesi için ağırlık parametrelerinin ayarlanması gibi ince ayar yapılabilir.

6. KAYNAKÇA

- [1] «A. Stambler, G. Sherwin and P. Rowe, "Detection and Reconstruction of Wires Using Cameras for Aircraft Safety Systems," 2019 International Conference on Robotics and Automation (ICRA), 2019, pp. 697-703, doi: 10.1109/ICRA.2019.8793526».
- [2] R. Madaan, D. Maturana and S. Scherer, «"Wire detection using synthetic data and dilated convolutional networks for unmanned aerial vehicles," 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017, pp. 3487- 3494, doi: 10.1109/IROS.2017.8206190».
- [3] «J. Qian, X. Mai and X. Yuwen, "Real-time Power Line Safety Distance Detection System Based on LOAM Slam," 2018 Chinese Automation Congress (CAC), 2018, pp. 3204-3208, doi: 10.1109/CAC.2018.8623168».
- [4] «John N. Sanders-Reed, Dennis J. Yelton, Christian C. Witt, Ralph R. Galetti, "Passive obstacle detection system (PODS) for wire detection," Proc. SPIE 7328, Enhanced and Synthetic Vision 2009, 732804 (6 May 2009); <https://doi.org/10.1117/12.815543>».
- [5] «D. S. Goshi, Y. Liu, K. Mai, L. Bui and Y. Shih, "Cable imaging with an active W-band millimeter-wave sensor," 2010 IEEE MTT-S International Microwave».
- [6] «J. Candamo, R. Kasturi, D. Goldgof and S. Sarkar, "Detection of Thin Lines using Low-Quality Video from Low-Altitude Aircraft in Urban Settings," in IEEE Transactions on Aerospace and Electronic Systems, vol. 45, no. 3, pp. 937-949, July 2009, doi: 10.110».
- [7] «Ö. E. Yetgin, B. Benligiray and Ö. N. Gerek, "Power Line Recognition From Aerial Images With Deep Learning," in IEEE Transactions on Aerospace and Electronic Systems, vol. 55, no. 5, pp. 2241-2252, Oct. 2019, doi: 10.1109/TAES.2018.2883879.».
- [8] «C. Zhou, J. Yang, C. Zhao and G. Hua, "Fast, Accurate Thin-Structure Obstacle Detection for Autonomous Mobile Robots," 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2017, pp. 318-327, doi: 10.1109/CVPRW.2017.45.».
- [9] «Biqin Song, Xuelong Li, Power line detection from optical images, Neurocomputing, Volume 129, 2014, Pages 350-361, ISSN 0925-2312, <http://dx.doi.org/10.1016/j.neucom.2013.09.023>».
- [10] «Ö. E. Yetgin and Ö. N. Gerek, "Cable and wire detection system for aircrafts," 2013 21st Signal Processing and Communications Applications Conference (SIU), 2013, pp. 1-4, doi: 10.1109/SIU.2013.6531237.».

7. TEŞEKKÜR

Bu projenin tamamlanmasında yardımlarından ve rehberliğinden ötürü Prof. Dr. Kemal Fidanboyly'ya teşekkür ederiz.

8. ÖZGEÇMİŞ

BİLGİSAYAR MÜHENDİSİ

MÜRSEL AYBARS ORMANLI

KİŞİSEL PROFİL

Hevesli geliştirici, sıkı çalışma, ayrıntılara dikkat ve mükemmel organizasyon becerileri yoluyla ekip başarısına katkıda bulunmaya istekli. Araştırma ve kendi kendine öğrenme konusunda net bir anlayış. Yazılım ve donanım geliştirmede öğrenmek, büyümek ve mükemmelleşmek için motive.

UZMANLIK ALANLARI

- Uygulamalı Unity ve C++ deneyimi
- Java ve Python deneyimi
- C ve C# çalışma bilgisi
- Blender ve Unity üzerinde bölüm tasarımı

DİĞER BECERİLER

- Karmaşık teknik bilgileri analiz etme becerisi
- Baskı altında doğru kararlar verebilme
- Grup yönetme becerisi
- Detaycı, mükemmel sorun çözücü

DİLLER

- İngilizce (İleri)
- Almanca (Başlangıç)
- Rusça (Başlangıç)

REFERANSLAR

• Prof. Dr. Kemal FİDANBOYLU
Bursa Uludağ Üniversitesi
Bilgisayar Mühendisliği Bölümü
öğretim üyesi
Mail: kfidan@uludag.edu.tr
Tel: +90(224) 295 5282

İLETİŞİM BİLGİLERİ

Cep: +90 (533) 575 03 55 ormanlaybars@gmail.com
3009/18 3. blok, daire 3, Paşakent Mahallesi, Yalova

İŞ DENEYİMİ

STAJYER

TERACİTY | 2021-08 – 2021-09
– SIRA TABANLI MULTIPLAYER MOBİL OYUN GELİŞTİRME VE DÖKÜMANTASYONUNU HAZIRLAMA

STAJYER

COMPARİSONATOR | 2020-07 – 2020-08
– BACK-END GELİŞTİRİCİ
– HTML, JAVASCRIPT, NODE.JS VE DİĞER YAZILIMLARLA BACK-END WEBSITE GELİŞTİRME

EĞİTİM GEÇMİŞİ

ULUDAĞ ÜNİVERSİTESİ

BİLGİSAYAR MÜHENDİSLİĞİ LİSANSI | DEVAM EDİYOR
GNO : 3.04

– DİJİTAL OYUNLAR VE ESPOR TOPLULUĞU KULÜP ÜYESİ

PROJELER

–DÖNER KANATLI HAVA ARAÇLARI İÇİN GERÇEK ZAMANLI TEL TESPİT SİSTEMİ

–GAME JAM KAPSAMINDA 72 SAATTE HAZIRLANAN HACK AND SLASH BİLGİSYAR OYUNU

–GAME JAM KAPSAMINDA 72 SAATTE HAZIRLANAN SONSUZ KOŞU PLATFORMER OYUNU

–SIRA TABANLI DİJİTAL SATRANÇ BENZERİ MASA OYUNU YAPAY ZEKASI

–SIRA TABANLI MULTIPLAYER MOBİL OYUN

–SIRA TABANLI SAVAŞ SİSTEMLİ 3D RPG OYUN

–İŞİTME CİHAZLARI İÇİN DEĞİŞKEN GÜRÜLTÜ FİLTRESİ

–MODEMLER İÇİN GECİKMELİ RESTART APARATI


Batuhan Özdemir

Computer Engineer,

Game Developer

Phone: +90 534 074 0841

E-mail: batuhan22.ozdemir@gmail.com



Studying Computer Engineering (2.98 GPA) at Uludağ University. Pursuing a career on Deep Learning & Computer Vision. Studying Tensorflow & Pytorch through online courses. Game Development Hobbyist.

EDUCATION

- **B.S. – Computer Engineering**
*Uludağ University,
 Bursa, Nilüfer
 2018 – Present
 204/240 Credits Fulfilled (14 missing in the form of Internship)
 2,98 GPA*

SKILLS

- OpenCV & Tensorflow: Studying basic concepts.
- MATLAB: Familiar to the interface and code usage.
- SQL: MySQL and PostgreSQL at beginner level.
- Version Control: Worked with GitHub, tried Git w/o any experience.
- Unity: Junior-mid game development.
- Blender: Basic 3D modeling and animaton.

EXPERIENCE

- Voluntary English – Turkish Translator in Digital Extremes (06, 2017 – 03, 2019) : [1]
- Magara Game Jam #3 & #4: [2]
- Game Development Class Project: Contributed on my version control skills, teamwork and time management.

GOALS

- Get into the field of Deep Learning with the assistance of those with experience.
- Study further to achieve Master's and Doctorate degrees on the field of Computer Vision & AI.
- Have great friendships among the workplace and the studies.

[1] Reference will be provided as it is needed.

[2] Work shall be provided through the e-mail attachment

Burak Yavuz Çengel

Address: Bursa/Görükle

E-mail: burakyavuzcengel@gmail.com

Phone: 0534 590 72 43

LinkedIn: linkedin.com/in/burakyavuzcengel2000

Education

Bursa Uludağ Üniversitesi 2018-2022

Computer Science 4th grade, 3.2 GDP

İzmir Kız Lisesi 2014-2018

Programming Languages/Environments

C#

C++

Unity2D/3D

MATLAB

Python

HTML/CSS/JS

Languages

English: Proficient User

Turkish: Native

Projects

- Magara Jam #3 submission with H4Ck n Slash, a hack and slash game with cyberpunk theme. Responsible for the fundamental combat systems and UI, abilities of player and NPCs, basic AI for enemies using Unity2D with C#.
- Firuze Hanım'ın Mürettebatı, A turn-based RPG. Responsible for the fundamental combat systems and UI, turn-based combat loop and basic AI for opponents using Unity3D with C#.
- Paint Runner, a casual runner game with the ability to draw platforms via mouse. Responsible for drawing mechanic, UI, projectile mechanics and parts of general game loop.
- Hearing aid for a school project using MATLAB.
- Power line detection using deep learning and image processing for rotorcrafts. (ongoing)